

《人工智能——深度学习大模型智能体》

实验报告

实验作业二

ConvLSTM 的算法应用与改进

姓 名：孙驰

学 号：2024311281

班 级：计算机 10 班

完成日期：2026 年 9 月 15 日

1 实验概述

1.1 实验目的

本实验围绕弹跳小球下一帧预测，理解 ConvLSTM 将输入到状态、状态到状态的矩阵变换改为二维卷积后，如何同时保留空间结构和时间记忆。通过手写细胞、推导参数量及完整训练，建立从序列数据到预测图像的实现流程。

在统一数据、训练轮数和随机种子下，对层数、隐藏通道、卷积核、输入帧数、网络结构和损失函数开展六组对照，评价预测质量与模型成本。结果表明，2 层、64 通道和 5×5 细胞核的组合将测试 MSE 降低 39.27%；增加输入帧数与改用 L1 未达到预期。

本实验使用 Codex 辅助实现与调试，结合单元测试、独立代码审查和保存预测的指标重算，保证结论来自实际运行。分析同时保留负面结果，避免仅凭损失下降就认定模型学会了运动。

1.2 实验环境

表 1 实验环境清单

类别	名称 / 版本	备注
操作系统	本地 Windows 11；HPC Linux 5.4	正式训练在 Slurm 计算节点
Python / PyTorch	3.10.20 / 2.6.0+cu124	NVIDIA A30 24GB； CUDA 12.4
NumPy / Matplotlib	1.24.4 / 3.10.9	本机另用 CPU 验证模型
数据集	脚本合成弹跳小球序列	训练 2000；测试 200；验证 200
AI 编程助手	Codex	代码生成、调试、审查与分析

数据设置：每条 10 帧，尺寸 32×32，球半径 2；x、y 速度分量的绝对值分别服从 0.8–1.6 像素/帧的均匀分布。种子 42 生成 2200 条，前 2000 条训练、后 200 条测试；额外用种子 43 生成 200 条验证序列。三部分经哈希核验没有重复序列。

指南示例用全部 2000 条训练、其中最后 200 条测试，存在数据泄漏，本实现予以修正。边界处将越界位置镜像折回，保证小球完整保留在画面内。验证集仅用于筛选有效改动；各组均使用第 5 轮模型，未按测试结果选择轮次。

计时口径：表中耗时统一为 GPU 同步后的“训练+逐轮测试/验证”，不含环境加载、数据生成、绘图和保存。基线纯训练 3.414 s。正式作业 10044 在 A30 上完成，包含测试、小数据检查和全套实验的总墙钟时间为 2 分 24 秒；不可直接与指南 CPU 估时比较。

2 基线实验

2.1 基线设置

表 2 基线 ConvLSTM 配置

项目	配置
任务设定	看前 4 帧 (32×32)，预测第 5 帧
ConvLSTM 细胞	C_in=1, C_h=32, K=3, 1 层
输出卷积	Conv2d(32→1, 3×3, padding=1)
损失 / 优化器	MSE / Adam(0.001), 批 64, 5 epoch
随机种子	42

2.2 参数量手算验证（必做）

表 3 参数量手算与核对

模块	公式代入过程	手算结果	代码核对
ConvLSTM 细胞	$4 \times (288 + 9216 + 32)$	38,144	一致: 38,144
输出卷积	$3 \times 3 \times 32 \times 1 + 1$	289	一致: 289
总参数量	$38,144 + 289$	38,433	一致: 38,433

每个门包含输入卷积、隐藏状态卷积和偏置；四门合计为 $4 \times [K^2 \times C_{in} \times C_h + K^2 \times C_h^2 + C_h]$ 。本细胞没有 peephole 连接，故不额外计入细胞状态到门的权重。代码核对使用各模块的 `sum(p.numel() for p in model.parameters())`，实际打印结果见附录。

2.3 基线结果

测试 MSE: 0.00454742 测试 MAE: 0.01315643 耗时: 3.582 s。




图 1 基线训练损失与测试 MSE 曲线 (result_baseline.png)

基线训练损失由 0.011086 降至 0.004800，测试 MSE 由 0.008803 降至 0.004547，训练过程正常收敛。全黑输出的测试 MSE 为 0.012139，因此基线已有实质改善；但 MAE 为 0.013156，仍高于全黑参照，提示前景稀疏时必须结合预测图评价。

3 对照实验（控制变量）

表 4 对照实验设计与结果记录表

组号	实验名称	改动内容	MSE	MAE	耗时 (s)	观察结论
0	基线	—	0.004547	0.013156	3.582	正常收敛
1	加深层数	2 层	0.003897	0.012633	6.765	MSE 降 14.30%
2	隐藏通道	32→64	0.004191	0.014214	4.334	MSE 降 7.83%；MAE 升
3	卷积核	3×3→5×5	0.003762	0.013766	2.908	MSE 降 17.26%
4	输入帧数	4→8 帧	0.004586	0.013042	6.403	MSE 升 0.85%
5	结构对照	全连接 LSTM	0.007319	0.033543	0.451	MSE 升 60.95%
6	损失函数	MSE→L1	0.011997	0.012737	3.304	接近全黑预测
7	最优组合	2 层/64 通道 /5×5 核	0.002762	0.010287	15.529	MSE 降 39.27%

六组实验均只改变表中一项，其余维持基线；正式 GPU 运行的实际批大小为 64。表 4 最优组合列为三次均值。exp3 只改变细胞卷积核，输出卷积仍保持 3×3。

3.1 实验 1：加深层数




图 2 实验 1 曲线 (result_exp1.png)

加深到 2 层后，测试 MSE 为 0.003897，比基线降低 14.30%，MAE 由 0.013156 降至 0.012633。参数量增至 112,289，训练加评估耗时 6.765 s，约为基线 1.89 倍。

两层结构使后一层可以继续整合前一层的时空表征，这与误差下降相符；但本实验未直接分析隐藏特征，不能仅凭指标断言已经学到“更抽象”的特征。收益需要与参数和计算开销一起考虑。

3.2 实验 2：隐藏通道




图 3 实验 2 曲线 (result_exp2.png)

隐藏通道增至 64 后，测试 MSE 降至 0.004191，改善 7.83%；MAE 却升至 0.014214，说明误差指标之间存在权衡。模型总参数量为 150,593，耗时 4.334 s。

更大的隐藏状态可以表达更多特征，但本次收益有限，不能把容量增加等同于全面改善。与基线相比 MSE 降低而 MAE 升高，说明大误差与小误差的分布发生变化；具体误差分布仍需进一步统计。

3.3 实验 3：卷积核




图 4 实验 3 曲线 (result_exp3.png)

将细胞卷积核扩大到 5×5 后，测试 MSE 为 0.003762，降低 17.26%，是六项单独修改中 MSE 最低的一组。更大的局部邻域有助于覆盖相邻帧的位移，这是对结果的合理解释。

该组 MAE 为 0.013766，略高于基线；参数量为 106,017。实测耗时 2.908 s 略低于基线 3.582 s，不能据此推断大核理论计算量更小；短时 GPU 测量还受卷积内核选择、启动开销及共享节点负载影响。

3.4 实验 4：输入帧数




图 5 实验 4 曲线 (result_exp4.png)

输入由 4 帧增至 8 帧后，测试 MSE 为 0.004586，较基线上升 0.85%；MAE 为 0.013042，略有下降。训练加评估耗时 6.403 s，接近基线的 1.79 倍。本次未观察到更多输入带来明显收益。

按照指南，4 帧组预测第 5 帧，8 帧组预测第 9 帧；除输入长度外，目标时刻及反弹分布也不同。因此这组差异不能纯粹归因于历史长度。若进一步研究，应统一预测时刻，再比较最近 4 帧和前 8 帧，并增加不同种子复测。

3.5 实验 5：结构对照




图 6 实验 5 曲线 (result_exp5.png)

全连接 LSTM 的测试 MSE 为 0.007319，较基线上升 60.95%，MAE 为 0.033543。总参数量 1,575,936，约为基线的 41.00 倍，却没有获得更好的预测质量。

展平后像素位置仍有固定索引，但网络没有显式的二维局部连接与卷积权重共享，需要从数据中学习空间邻接关系。本次结果支持卷积结构适合该任务；不能推广为全连接 LSTM 在所有任务上都更差。其 GPU 耗时仅 0.451 s，也说明参数量不直接等于实际运行时间。

3.6 实验 6：损失函数




图 7 实验 6 曲线 (result_exp6.png)

L1 组测试 MSE 为 0.011997，较基线上升 163.81%；MAE 为 0.012737，虽略低于基线，预测却接近全黑。全黑参照 MSE/MAE 均约 0.012139，说明该组几乎未学到有效的小球位置。

小球只占约 1.2%的像素，背景占绝大多数。在 5 轮训练下，压低背景误差成为容易达到的解。L1 对异常误差较不敏感不保证本任务中更好；本次未观察到“预测更锐利”的效果。

4 AI 协作记录（Codex 使用情况）

表 5 Codex 协作过程记录

序号	协作环节	我的参与与关注点	Codex 辅助工作与反馈
1	明确任务依据	我指定作业二指南位置，要求按课件完成实验并上传 Git；先完成实验，再按模板整理报告。	依据指南实现基线、六组对照与三次复测；检查并修正示例中的训练/测试重叠。
2	提供运行条件	我提供 HPC 平台文档和学号，说明本机已有免密登录条件，为正式训练提供可用环境。	连接既有环境并编排 Slurm 任务；定位内存申请失败原因，调整后在 A30 上完成训练。
3	追问实验效果	我主动追问：“实验结果如何？是否符合预期？是否按照指导要求？”要求同时评价效果与完成情况。	核对要求、指标及预测图；解释 8 帧组未改善和 L1 近全黑现象，明确同种子复测的结论范围。

协作反思：实验评价应同时看误差、预测图和对照条件。8 帧组与 L1 组未达到预期，说明训练完成或某项指标下降，都不足以证明改动有效。

5 结果分析

5.1 最优组合复测

表 6 最优组合 3 次复测结果

运行次数	随机种子	测试 MSE	测试 MAE	耗时 (s)
第 1 次	42	0.00276185	0.01028703	15.630
第 2 次	42	0.00276185	0.01028703	15.435
第 3 次	42	0.00276185	0.01028703	15.522
平均值	同种子 42	0.00276185	0.01028703	15.529

按独立验证集最终 MSE，层数、通道数和卷积核三项有效，故组合为 2 层、64 通道、5×5 细胞核，仍用 4 帧输入及 MSE 训练。组合验证 MSE 为 0.00286881，测试 MSE 较基线降低 39.27%，MAE 降低 21.81%。

三次均重新初始化模型、重置种子 42 并完成 5 轮训练，模型参数与 200 个测试预测逐位一致。这证明本环境下的确定性复现；三次并非独立随机样本，不能据零标准差宣称具有跨种子的统计显著性。

5.2 预测帧对比分析




图 8 输入帧 | 真实帧 | 预测帧 对比图 (result_pred.png)

图 8 使用测试样本 0、100、199，分别对应 MSE 0.003361、0.002299、0.002952。样本 0 向右上方移动，样本 199 向左下方移动；预测覆盖了大致位置，但轮廓比真实二值小球模糊。样本 100 在输入第 2 至第 3 帧间触及上边界并反弹，模型能给出反弹后大致运动方向。

三个样本的合速度分别约为 1.333、1.921、1.964 像素/帧，误差没有随速度单调变化，因此不能仅用这三张图断言“越快越差”。补充统计 200 个测试样本：第 4 至第 5 帧间恰好发生反弹的 21 条，组合平均 MSE 为 0.005647；其余 179 条为 0.002423。反弹组误差更大，但组间速度、位置也不同，该统计是描述性证据。

预测值不经裁剪直接计算误差；绘图统一显示范围[0,1]。图像上的灰色和拖影反映预测的不确定性或位置偏差，不能只看小数形式的 MSE 就认定视觉质量已经足够好。

5.3 总结论

（1）在本数据和 5 轮训练条件下，加深、加宽与扩大卷积核均改善 MSE，其中 5×5 核的单项收益最大；这不是对所有时空任务的普遍排序。

（2）有效改动组合后取得最低 MSE 与 MAE，但总参数量增至 1,236,289，约为基线 32.17 倍，训练加评估耗时约 4.34 倍。精度提升伴随明确的资源成本。

（3）增加输入长度没有保证收益；需要同时考虑目标时刻、训练预算和反弹模式。L1 组近全黑的结果说明稀疏前景下应结合多指标和预测图评价。

（4）独立划分数据、用验证集选择配置、保留失败组和保存原始预测，比追求单一“漂亮数字”更重要。本次未实施多步预测等额外训练加分项。

6 思考题作答

(1) ConvLSTM 与普通 LSTM 的本质区别？为什么保留二维空间结构对预测运动序列特别重要？

普通 LSTM 通常将每帧展平，用矩阵乘法更新门和状态；ConvLSTM 将输入和隐藏状态保留为二维特征图，在输入到状态、状态到状态的变换中使用卷积。细胞状态仍按 $C_t = f_t \odot C_{t-1} + i_t \odot g_t$ 更新，隐藏状态为 $H_t = o_t \odot \tanh(C_t)$ 。

保留二维结构使相邻像素在局部感受野内共同参与计算，同一卷积核可用于不同位置。小球运动表现为局部图案的位移，卷积因此提供了适合本任务的结构约束；全连接模型虽未丢失固定位置索引，却需要额外学习这种空间邻接关系。

(2) C_h 从 32 增至 64 时单个细胞参数量变为多少？增长几倍？说明容量与成本的权衡。

64 通道细胞参数量为 $4 \times (576 + 36,864 + 64) = 150,016$ ，其中三项分别是单门的输入卷积、状态卷积和偏置。相对 38,144 增至 3.9329 倍，即增加约 293.29%。主要原因是隐藏状态卷积项与 C_h^2 成正比。

加入输出卷积 577 个参数后，总量为 150,593。本次 MSE 改善 7.83%，MAE 反而变差，说明容量增加的收益并不与参数量成比例，应结合内存、运算时间和实际指标选择通道数。

(3) 全连接 LSTM 对照的参数量是多少？从参数量与空间局部性解释其与 ConvLSTM 的表现差异。

PyTorch `nn.LSTM(1024,256)` 有输入权重 $4 \times 256 \times 1024$ 、循环权重 $4 \times 256 \times 256$ ，以及两套长度 4×256 的偏置，合计 1,312,768。输出 `Linear(256,1024)` 有 $256 \times 1024 + 1024 = 263,168$ 个参数；总计 1,575,936，约为基线 ConvLSTM 的 41.00 倍。

4 帧是时间轴长度，每一步输入仍是 1024 维，不能把 `input_size` 写成 4096。该模型参数更多但 MSE 更高，结合卷积的局部连接与共享权重，可解释为本任务中卷积结构更节省学习空间规律所需的数据；当前实验不能区分优化、训练轮数与结构因素各自的贡献。

(4) 增加输入帧数为什么能提升预测精度？加到 16 帧可能遇到什么问题？

更多历史帧在原则上有助于估计速度、方向和反弹前后的轨迹，但收益取决于信息是否有用、网络是否学得动。本次 8 帧组没有降低 MSE，所以该题中的“能提升”应理解为可能的机制，而非必然结论。

若看 16 帧预测第 17 帧，必须把序列长度从 10 至少扩展到 17；时间展开更长会增加运算、激活内存和反向传播路径，早期信息还可能冗余或经过多次反弹。后续比较应统一目标时刻和训练预算，避免将目标变化混入输入长度效应。

(5) 气象降水临近预报中 ConvLSTM 的输入与输出各是什么？与弹跳小球相比有哪些额外难点？

在降水临近预报中，输入通常是连续多个时刻、经过配准和质量控制的雷达回波或降水强度二维网格；输出是同一区域未来一个或多个时刻的回波或降水强度图。Shi 等将其建模为时空序列预测，用卷积递归同时建模空间关系和时间变化[1]。

与恒定形状的小球相比，真实回波会生成、增强、衰减和消失，并存在旋转、形变、多尺度运动及观测噪声；强降水样本稀少，平均像素误差未必反映预警价值。后续研究进一步指出位置相关运动与评价协议的重要性[2]。因此实际系统需要多步评估及强降水分级指标，不能直接沿用小球任务的单一 MSE 结论。

(6) 实现 ConvLSTMCell 时，AI 在哪些环节最有价值？哪些地方必须自己读懂公式才能改对？

我认为，AI 最有价值的环节是把门控公式落实为可运行代码，并处理状态初始化、设备匹配、批量实验和指标整理等工作。本次协作中，我明确实验依据、提供 HPC 条件，并追问结果是否符合预期与指导要求；Codex 承担代码实现、运行和核验，具体分工见第 4 节。

我需要理解的是四门分别控制什么、c 与 h 为何采用不同更新方式，以及输入拼接后的通道数为何为 $C_{in}+C_h$ 、四门输出为何为 $4C_h$ 。参数核对还必须分清时间轴与特征轴：4 帧不意味着 `input_size` 变成 4096。只有能解释这些关系，才能判断生成代码是否符合模型原理；评价改进时也应结合数据划分和预测图，避免把泄漏或背景占优造成的低误差当作有效学习。

附录 参数核对与复现材料

以下图像由本机实际执行的参数核对打印文本生成，用于保留原始数值；不是模拟的 IDE 界面截图。

```
ConvLSTM cell = 38144
Output Conv2d = 289
ConvLSTM total = 38433
FlattenLSTM total = 1575936
Formula verification: True
```

图 9 参数核对实际运行输出

运行与验证：python -m unittest test_convlstm -v; python convlstm_bounce.py --suite all --device cuda --micro-batch 64 --output results_gpu; python verify_results.py。正式 HPC 作业编号 10044, 状态 COMPLETED, 退出码 0:0, 资源已释放。

实验数据与代码：GitHub 仓库 s-max-oss/llm-course-labs, lab02 目录，实验提交 8152453。results.json 为全组汇总，predictions_*.npz 保存原始预测，*.pt 保存权重，slurm-10044.log 保存运行日志，verification.json 记录指标和模型重放核验。

<https://github.com/s-max-oss/llm-course-labs/tree/8152453/lab02>

参考资料

- [1] Shi X, Chen Z, Wang H, et al. Convolutional LSTM Network: A Machine Learning Approach for Precipitation Nowcasting. NeurIPS, 2015. <https://arxiv.org/abs/1506.04214>
- [2] Shi X, Gao Z, Lausen L, et al. Deep Learning for Precipitation Nowcasting: A Benchmark and A New Model. NeurIPS, 2017. <https://arxiv.org/abs/1706.03458>
- [3] 课程资料：《作业二_ConvLSTM 的算法应用与改进_实验指南》及实验报告样板；Lesson04《循环神经网络》。