

《人工智能——深度学习大模型智能体》

实验报告

实验作业三

手搓最小 LLM——使用 CPU 训练

姓 名：孙驰

学 号：2024311281

班 级：计算机 10 班

完成日期：2026 年 9 月 23 日

1 实验概述

1.1 实验目的

本实验从零实现字符级自回归语言模型，在 CPU 上学习下一字符预测。核心实现包括 Q/K/V 投影、多头因果注意力、残差连接、Pre-Norm、GELU 前馈层、可学习位置嵌入和输入输出权重共享，未调用现成 Transformer 层，注意力结构原理参照文献[7]。

通过 2000 步基线、八个 1000 步训练变体，以及温度、top-k 和禁止重复 3-gram 的采样对照，分析模型容量、优化与生成策略之间的关系。结果显示，约 50 万参数的模型能快速拟合 2163 字符的小语料，但主要表现为原诗续写和记忆，尚不能据此认定具有原创作诗或对话能力。

1.2 实验环境

表 1 实验环境清单

类别	名称 / 版本	备注
操作系统	HPC Linux 5.4.0-100; 本地 Windows	正式训练在 Slurm 计算节点
CPU 与线程	Xeon Platinum 8358 @2.60GHz	节点 gpu4; 每模型 4 线程
Python	正式 3.10.20; 本地核验 3.11.16	生成原文使用正式环境
PyTorch	正式 2.6.0+cu124; 本地 2.14.0+cpu	模型、数据均为 CPU, 无 GPU 申请
Matplotlib	3.10.9	保存逐组曲线与汇总图
AI 助手	Codex	实现、解释、审查、运行与报告整理

语料逐字提取自指南的 72 段诗文，含换行和标点共 2163 字符，去重词表 699。正式训练未追加扩充语料；字符排序建立稳定索引，训练输入与标签错开一位。语料含宋、明、清等作品，不能把全部内容都称为唐诗。

本实验按指南使用小语料训练，未另设独立测试集。固定窗口 loss 仅评价训练语料拟合；不同实验的参数、曲线和原文均单独保存，避免同名文件覆盖。

2 基线实验

2.1 基线设置

表 2 基线模型与训练配置

项目	基线值
词表 V / 嵌入 C	699 / 128
注意力 H / 层数 L	4 头（每头 32 维）/ 2 层
上下文 T / MLP 隐层	128 / 512（GELU）
优化器 / 学习率	AdamW / 0.001；weight_decay=0.01
批大小 / 更新次数	32 / 2000
随机种子 / 设备	42 / CPU，4 线程
生成设置	temperature=1.0，top_k=20，新增 200 字符

2.2 基线结果

精确参数量 502,656；末步训练 loss 为 0.029191；最后 100 步均值 0.030087；最终固定训练窗口 loss 为 0.023166。初始固定窗口 loss 为 6.566851，接近 $\ln(699)=6.549651$ ；第 1 步批次 loss 为 6.566773。

纯训练时间 118.77 秒，约 1.98 分钟，不含评估、绘图、保存及进程启动。正式作业 10765 共用 4 分 36 秒，最多三个模型并行；该作业总墙钟时间不能作为单模型耗时。




图 1 基线 2000 步训练曲线

loss 快速下降后在低位波动。1000 步快照的固定窗口 loss 为 0.022845，略低于 2000 步的 0.023166，因此继续训练没有带来稳定改善。

基线生成原文

以下保留「春」「月」各两段完整输出，含提示字共 201 字符。换行沿用原文，末尾可能因固定生成长度而截断。

提示词「春」 第 1 段 seed=1001

春晖。

山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。
纸上得来终觉浅，绝知此事要躬行。古人学问无遗力，少壮功夫老始成。
死去元知万事空，但悲不见九州同。王师北定中原日，家祭无忘告乃翁。
小荷才露尖尖角，早有蜻蜓立上头。泉眼无声惜细流，树阴照水爱晴柔。
接天莲叶无穷碧，映日荷花别样红。毕竟西湖六月中，风光不与四时同。
胜日寻芳泗水滨，无边光景一时新。等闲识得东风面，万紫千红总是春。

提示词「春」 第 2 段 seed=1002

春色来天地，玉垒浮云变古今。

独怜幽草涧边生，上有黄鹂深树鸣。春潮带雨晚来急，野渡无人舟自横。
天街小雨润如酥，草色遥看近却无。最是一年春好处，绝胜烟柳满皇都。
昔人已乘黄鹤去，此地空余黄鹤楼。黄鹤一去不复返，白云千载空悠悠。
晴川历历汉阳树，芳草萋萋鹦鹉洲。日暮乡关何处是，烟波江上使人愁。
客舍青青柳色新，渭城朝雨浥轻尘。劝君更尽一杯酒，西出阳关无故人。
寒雨连江夜入吴，平明送客楚山孤。洛阳亲友如

提示词「月」 第 1 段 seed=1003

月两相和，潭面无风镜未磨。遥望洞庭山水翠，白银盘里一青螺。

杨柳青青江水平，闻郎江上踏歌声。东边日出西边雨，道是无晴却有晴。
自古逢秋悲寂寥，我言秋日胜春朝。晴空一鹤排云上，便引诗情到碧霄。
前不见古人，后不见来者。念天地之悠悠，独怆然而涕下。
葡萄美酒夜光杯，欲饮琵琶马上催。醉卧沙场君莫笑，古来征战几人回。
黄河远上白云间，一片孤城万仞山。羌笛何须怨杨柳，春风不度玉门关。
秦时明月汉时关，万里长征

提示词「月」 第 2 段 seed=1004

月两相和，潭面无风镜未磨。遥望洞庭山水翠，白银盘里一青螺。

杨柳青青江水平，闻郎江上踏歌声。东边日出西边雨，道是无晴却有晴。
自古逢秋悲寂寥，我言秋日胜春朝。晴空一鹤排云上，便引诗情到碧霄。
前不见古人，后不见来者。念天地之悠悠，独怆然而涕下。
葡萄美酒夜光杯，欲饮琵琶马上催。醉卧沙场君莫笑，古来征战几人回。
黄河远上白云间，一片孤城万仞山。羌笛何须怨杨柳，春风不度玉门关。
秦时明月汉时关，万里长征

两段「月」虽然种子不同，却完全一致。句子通顺主要来自训练原文续写；不应把背诵当作新诗创作。

3 参数量手算验证（必做）

近似公式： $N \approx V \times C + T \times C + L \times 12C^2$ 。输出层与词嵌入共享同一个 Parameter，只计一次；近似式略去线性层偏置与 LayerNorm 参数。

表 3 参数量手算与代码核对

模块	代入与计算	近似参数	代码参数
词嵌入及共享输出	699×128	89,472	89,472
位置嵌入	128×128	16,384	16,384
两层 Transformer	$2 \times 12 \times 128^2$	393,216	396,544
最终 LayerNorm	2×128 （近似式忽略）	0	256
合计	$89,472 + 16,384 + 393,216$	499,072	502,656

每层注意力权重为 $4C^2$ ，MLP 权重为 $8C^2$ ；额外 $13C$ 由注意力偏置 $4C$ 、MLP 偏置 $5C$ 、两处 LayerNorm 的 $4C$ 组成。精确式为 $V \times C + T \times C + L \times (12C^2 + 13C) + 2C$ 。

基线差额为 $2 \times 13 \times 128 + 2 \times 128 = 3,584$ ，相对代码值误差 $3,584 \div 502,656 \approx 0.713\%$ ，满足小于 1% 的要求。共享关系和 `sum(p.numel())` 均经实际执行核对，输出见附录。

4 对照实验（控制变量）

exp1—exp5 每种设置统一训练 1000 步，并与同一基线的 1000 步快照比较。所有组使用原始语料、batch32、seed42 及相同优化器设置；表 4 的“最终 loss”统一指末步批次 loss。辅助比较使用固定训练窗口 loss，避免单个随机批次误导排序。1000 步基线末步 loss 为 0.027142，固定窗口 loss 为 0.022845，纯训练 59.92 秒。

两项限制需要保留：宽度组按指南同时调整头数，维持每头 32 维；T=32 组每步仅处理 1024 字符，为基线 4096 字符的四分之一。因此同更新次数不等于同 token 数或同计算量。

表 4 对照实验设计与结果记录表

编号	对照维度	基线值	实验值	末步 loss	质量	现象
exp1	学习率	0.001	0.01	0.101520	2/5	后期波动、重复
exp1	学习率	0.001	0.0001	0.623159	1/5	收敛慢、错接多
exp2	层数	2	1	0.029868	3/5	较快，局部错接
exp2	层数	2	4	0.032410	4/5	更慢，收益有限
exp3	宽度/头数	128/4	64/2	0.049458	2/5	容量小，错误多
exp3	宽度/头数	128/4	256/8	0.030819	4/5	拟合更好，仍背诵
exp4	上下文	128	32	0.107180	3/5	短上下文且 token 少
exp5	位置嵌入	有	无	0.032457	3/5	仍成句，错接增多
exp6	采样温度	1.0	0.5	不重训	4/5	趋向原诗续写
exp6	采样温度	1.0	1.5	不重训	2/5	错误拼接增多

星级以“得分/5”表示，由 Codex 整理报告时对保存的全部样本按稳定性综合主观评阅：1=多数不连贯；2=可读程度不稳定，存在大段破碎或明显拼接；3=多数局部可读但有明显错接；4=局部续写稳定、少量错误；5=局部及整体连贯且无明显异常。基线 1000 步和 2000 步均为 4/5。该评级不等同于原创性或人类盲评。

4.1 实验 1：学习率




图 2 学习率 0.01（左）与 0.0001（右）

0.01 组末步 loss 为 0.101520、固定窗口 loss 为 0.090003，明显高于同为 1000 步的基线 0.022845；曲线下降后有反复波动，但没有 NaN 或持续发散。原文出现“苍苍苍苍苍竹林寺”等重复，不应为迎合预期而写成数值发散。

0.0001 组末步 loss 为 0.623159，最后 100 步均值 0.724663，说明学习率过小使固定预算内拟合较慢，文本存在较多破碎拼接。三种学习率使用相同初始化，初始 loss 均接近 6.55；本条件下 0.001 更合适。

4.2 实验 2：层数




图 3 1 层（左）与 4 层（右）

1 层和 4 层的末步 loss 分别为 0.029868 和 0.032410，差 0.002542；固定窗口 loss 分别为 0.027899 和 0.027648，均略高于 2 层基线 1000 步的 0.022845。不同口径下排序不同，所以不能只凭最后一个批次判断优劣。

参数量由 304,384 增至 899,200，纯训练由 34.62 秒增至 107.71 秒，约 3.11 倍。4 层样本局部更稳定，但仍有错接；在此小语料和 1000 步预算下，加深没有带来明显的拟合收益。

4.3 实验 3：嵌入维度




图 4 C64/H2（左）与 C256/H8（右）

C 从 64 增至 256 时，参数量由 153,024 增至 1,791,744，约 11.71 倍；纯训练由 30.26 秒增至 141.65 秒，约 4.68 倍。注意力及 MLP 主项按 C^2 增加 16 倍，但嵌入的线性项也占一定比例，故总参数不恰好为 16 倍。

固定窗口 loss 由 0.046519 降至 0.020955，大模型优于基线 1000 步的 0.022845；原文局部完整性也较好。不过仍主要续写已见诗句，部分片段有错接。参数和时间增长不能解释为等比例的创作质量提升。

4.4 实验 4：上下文长度




图 5 上下文 T=32 的 1000 步训练曲线

T=32 组末步 loss 为 0.107180，固定窗口 loss 为 0.090093，纯训练 16.15 秒。仍能输出局部诗句，但可见“滚滚滚滚来”等重复和句间跳转；没有开展音韵标注，不能据主观阅读断言押韵率降低了多少。

较短上下文减少可利用的历史信息，也使 1000 步训练字符总量降至 1,024,000，而 T=128 组为 4,096,000。当前差异同时包含上下文和学习预算的影响；若研究上下文的纯效果，应再匹配训练 token 数并使用统一评价条件。

4.5 实验 5：位置编码




图 6 去掉位置嵌入后的 1000 步训练曲线

无位置嵌入组参数量 486,272，正好减少 $128 \times 128 = 16,384$ 。末步 loss 为 0.032457，固定窗口 loss 为 0.027912，纯训练 51.95 秒。loss 仍很低，表明模型能学习局部搭配和语料续接，并未完全失去语言结构。

生成中既有完整诗句，也有“愿君歌白日绮窗前”“昔人已乘黄鹤楼。黄鹤去”等错接，整体评级 3/5。因果掩码仍限定每个位置只能访问前缀，故模型不能简单视为完全没有顺序信息；位置嵌入是显式位置表示，而不是唯一可能的位置线索。

对照结果的解释范围

以上均为单个训练种子、同一极小语料的结果。不同结构可能改变初始化随机数消耗；同 seed 不能保证所有共享层具有相同初值。计时受并发任务与节点负载影响，例如高学习率组较慢不能归因于学习率本身增加了理论运算量。

基线 1000 步已能较好拟合；4 层没有稳定胜过 2 层，加宽虽降低拟合 loss 但成本较高。对于本次教学目的，2 层、128 维、学习率 0.001 已提供较好的成本与效果平衡。

5 采样分析（温度与 top-k）

5.1 采样实验记录

表 5 采样实验记录表（固定基线模型与提示词「春」，每组贴 2~3 句原文）

组号	温度	top-k	春提示原文摘录	观察
1	1.0	20	春晖。 山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。	原诗连续续写，春样本无段内重复
2	0.5	20	春草明年绿，王孙归不归。 花间一壶酒，独酌无相亲。举杯邀明月，对影成三人。	续写路径改变，仍主要背诵
3	1.5	20	春来发几枝。愿君歌声。愿君多采撷，此物最相思。	出现“愿君歌声”等错接
4	1.0	5	春晖。 山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。	春、月不变，山样本改变
5	1.0	699	春晖。 山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。	三段均与 k20 完全相同

五组均固定 2000 步基线模型，每组使用提示「春、月、山」，种子依次 1001、1002、1003，各生成 200 个新字符。表 5 展示春提示前 3 句（首句可能是短残句），完整原文全部保存在 results/sampling。top-k=699 相当于不截断。

基线原文展示的月提示种子为 1003、1004；本节月提示固定 1002。两套样本用途不同，采样策略之间的比较只使用本节统一的提示和种子。

5.2 生成对比分析

temperature=1.0 top_k=20 春 / seed=1001

春晖。山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。
纸上得来终觉浅，绝知此事要躬行。古人学问无遗力，少壮功夫老始成。
死去元知万事空，但悲不见九州同。王师北定中原日，家祭无忘告乃
……（此图为原始输出摘录排版，完整文本保存在仓库）

temperature=0.5 top_k=20 春 / seed=1001

春草明年绿，王孙归不归。花间一壶酒，独酌无相亲。举杯邀明月，对影成三人。
小时不识月，呼作白玉盘。又疑瑶台镜，飞在青云端。
长安一片月，万户捣衣声。秋风吹不尽，总是玉关情。弃我去者，昨日之日不可留
……（此图为原始输出摘录排版，完整文本保存在仓库）

temperature=1.5 top_k=20 春 / seed=1001

春来发几枝。愿君歌声。愿君多采撷，此物最相思。独放松，周星垂平明月中。
慈母手中线，游子身上衣。临行密密缝，意恐迟迟归。谁言寸草心，报得三春晖。
山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年
……（此图为原始输出摘录排版，完整文本保存在仓库）

temperature=1.0 top_k=5 春 / seed=1001

春晖。山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。
纸上得来终觉浅，绝知此事要躬行。古人学问无遗力，少壮功夫老始成。
死去元知万事空，但悲不见九州同。王师北定中原日，家祭无忘告乃
……（此图为原始输出摘录排版，完整文本保存在仓库）

temperature=1.0 top_k=699 春 / seed=1001

春晖。山重水复疑无路，柳暗花明又一村。莫笑农家腊酒浑，丰年留客足鸡豚。
纸上得来终觉浅，绝知此事要躬行。古人学问无遗力，少壮功夫老始成。
死去元知万事空，但悲不见九州同。王师北定中原日，家祭无忘告乃
……（此图为原始输出摘录排版，完整文本保存在仓库）

图 7 保存的生成原文摘录排版（春，seed=1001）

低温 0.5 更偏向高概率续接，输出较稳定；温度 1.5 增加低概率字符被选中的机会，产生“独放松，周星垂平明月中”等不连贯片段。高温带来的变化并不等于高质量新意。本次 T=1.0、k20 与不截断的三段逐字相同，可能反映模型在小语料上概率分布十分集中。

以稳定展示诗句续写为目标，我倾向保留 temperature=1.0、top-k=20：文本局部通顺，且比低温保留更多可选择路径。该选择是本批样本的折中，未证明是全局最优；若强调原创性，单改采样策略不足以克服小语料记忆。

5.3 选做 禁止重复 3-gram 与定量补充

在同一最终基线上，仅增加 no_repeat_ngram=3，禁止选择会使已有三字符片段再次出现的下一字符。模型、提示、种子、温度 1.0 和 top-k20 保持不变。该约束在采样时生效，不涉及重训。

表 6 三个固定提示的平均字符统计

采样设置	段内 3-gram 重复	语料 10-gram 匹配	不同字符占比
T1.0 / k20	0.34%	100.00%	68.67%
T0.5 / k20	0.34%	99.83%	69.33%
T1.5 / k20	2.19%	65.45%	66.50%
T1.0 / k5	0.34%	100.00%	72.83%
T1.0 / k699	0.34%	100.00%	68.67%
T1.0 / k20 / 禁止 3-gram	0.00%	93.72%	68.67%

统计仅使用新增 200 字符，保留标点和换行。段内重复率=1-不同三元组数量/三元组总数；10-gram 匹配率指生成的连续 10 字符片段在训练语料中出现的比例；不同字符占比=不同字符数/200。三项均按每段计算后取平均。

基线采样段内重复已很少，禁止 3-gram 仅将 0.34%降到 0%，绝对改善约 0.34 个百分点；同时原文出现“千尺多烦忧”“抽刀断楚江水复疑是银河落九天”等拼接，主观评级从 4/5 降至 3/5。可见强制消除重复不保证语言质量。

温度 1.5 的语料 10-gram 匹配率降至 65.45%，但不同字符占比反而降至 66.50%，同时重复率升至 2.19%。因此不能把任何单一指标直接当作多样性或原创性的完整度量。普通温度组接近 100%的匹配率，更支持“记忆训练语料”的解释。

上述重复率不衡量不同样本之间的相同程度：第 2 节两段月输出完全相同，段内重复率仍可为 0%。本实验没有独立测试集、语义一致性自动评价或多人盲评，所有质量结论限于保存的这些样本。

6 AI 协作记录（Codex 使用情况）

表 7 Codex 协作过程记录

序号	协作场景	我的要求与操作	Codex 辅助及处理
1	任务拆解与交付顺序	提供实验三指导书,要求“辅助我完成”;样板更新后明确“先把代码写出来”——先交付可运行代码、测试与原始结果,报告随后整理,不提前写结论。	读取 12 页指南,核对 72 段诗文、2163 字符、699 词表,按“数据→注意力→模型→训练→采样”分阶段实现并给出分子模块阅读入口;我据此确认 CPU 训练、2000 步基线、八个 1000 步变体的框架。
2	关键实现原理的核对	要求逐段讲解容易写错的地方,并给出可自检的判据:标签错开一位、Q/K/V 由 (B,T,C) 到 (B,H,T,C/H) 的轴变换、因果掩码在 softmax 前填 $-\infty$ 、输出层与词嵌入必须共享同一个 Parameter。	逐段解释并在代码中标注阶段入口;测试覆盖未来 token 不影响过去输出及其梯度、权重共享对象一致、有无位置嵌入两种情况下的因果性,我逐项确认后采用。
3	长时训练的可靠性审查	要求说明 HPC 训练中断后会怎样,并明确“确保 HPC 正常收尾关闭”。	独立审查发现强制退出后锁残留、完成标记未校验产物两处隐患,改为系统文件锁、必需产物 SHA256 清单与原子保存;复核强制中断 250 步后恢复,其逐步 loss、评估与所有权重与连续训练完全一致。
4	运行与资源限制处理	明确只用 CPU、不申请 GPU;要求记录真实训练耗时,不把作业墙钟时间当作单模型耗时。	先在 Slurm 计算节点实测 4 线程 CPU 速度;9 任务数组触及 QOS 提交数限制,改在单个 12CPU 作业内最多并行 3 个训练进程;作业 10765 COMPLETED、退出码 0:0,队列已清空。
5	复查、评价口径与报告整理	要求“再次检查代码、数据等,完成实验报告,同步代码仓库”;强调末步 loss 不能单独用于排序,须与固定训练窗口 loss 并列;不符合预期的结果不得删改。	复查 6 项测试、47 项产物哈希、9 个模型与 1000 步快照重放、58 段原文及采样统计;补充第 901—1000 步 loss 均值与快照签名;保留高温错接、禁止 3-gram 造成拼接等负面结果,并按新版样板补齐章节、图与表。

本次协作中,我负责确定课程目标、交付顺序与验收口径:先用 CPU 跑通 2000 步基线,再以统一的 batch32、seed42 展开八个 1000 步变体,最后做采样对照;Codex 承担具体代码实现、运行编排、独立审查和报告整理。代码中提供分段阅读入口,协作记录覆盖需求、实现、审查和结果整理四个阶段,完整过程保存在仓库的 AI_COLLABORATION.md 中。

工程层面的主要收获来自审查而非生成。Codex 在独立审查中发现强制退出后锁残留、完成标记未校验产物、从其他目录启动时相对输出路径不一致等问题,改用系统文件锁、必需产物 SHA256 清单与原子模型保存,并补充 1000 步快照签名。我对“强制中断 250 步后恢复”的复核结果逐项确认:续训与连续训练在逐步 loss、评估指标和全部权重上完全一致。这类检查比观察生成结果更能暴露实现错误。

评价口径由我把关。末步批次 loss 会受单个随机批次影响,因此我要求所有排序同时给出固定训练窗口 loss,并与 1000 步快照对照;报告保留高温采样错接、禁止 3-gram 反而降低可读性等不符合预期的结果,不把训练 loss 很低解释为泛化能力,也不把原诗续写当作原创能力。星级评级只按样本稳定性打分,其主观性已在正文注明,评级依据保存在 report/quality_ratings.json。

对我而言,判断 AI 输出是否可靠的关键是能解释模型原理与评价口径:低 loss 是否只来自记忆、单变量是否真的保持了相同预算,以及生成原文是否支持结论。要求 AI 提供可核对的依据(参数计数实际输出、训练曲线、产物哈希清单)之后,这些判断才有落脚点;遇到与指南表述不一致之处(如“无位置编码即与排列无关”的简化说法),我按因果掩码下的实际行为要求改写,而不是照抄题目提示。

整个流程中,AI 最有价值的地方是把指南转为可运行实现、检查张量形状、补充测试和定位工程故障;而实验框架、评价口径、结论边界以及是否如实保留负面结果,必须由我决定。我的体会是:AI 能显著加快实现与核验速度,但“读懂”与“负责”无法外包——只有我能解释清楚每一处改动为什么必要,这份实验才算真正完成。

7 思考题作答

(1) 结合 exp5: 去掉位置编码后, 模型还能学到什么? 生成的“诗”还成句吗? 为什么?

模型仍能学习字符共现、局部搭配、常见诗句及其续接。exp5 固定窗口 loss 为 0.027912, 能生成不少完整句子, 但也出现错序和跨诗拼接; 因此去掉显式位置嵌入并不使模型完全无法训练。

需要纠正题目提示中的简化说法: 不加位置、没有因果掩码的自注意力对排列通常是“等变”, 即输入重排会导致输出对应重排, 并非所有输出数值不变。这里使用固定的因果掩码, 每个位置可见的前缀不同, 任意重排会改变可见关系, 不能再称整个模型完全排列不变。相关研究发现无位置编码的因果语言模型也可能学习隐式位置线索[2]; 本实验未做探针分析, 不能据此断定本模型采用了哪种具体机制。

(2) 手算: 若 n_embd 从 128 增至 256、层数从 2 增至 3 (V、T 不变), 总参数量约为多少? 相比基线增长几倍? 结合 exp2 / exp3 的实测时间, 说明容量与训练成本的权衡。

近似参数量为 $699 \times 256 + 128 \times 256 + 3 \times 12 \times 256^2 = 178,944 + 32,768 + 2,359,296 = 2,571,008$ 。相对基线近似 499,072, 约为 5.15 倍。若计入偏置与 LayerNorm, 则再加 $3 \times 13 \times 256 + 2 \times 256 = 10,496$, 精确为 2,581,504, 相对精确基线 502,656 约 5.14 倍。

实际 C64 到 C256 使参数约增至 11.71 倍、训练时间增至 4.68 倍; 1 层到 4 层耗时约 3.11 倍。更大模型需要更多内存和计算, 但小语料上的收益有限。时间还受矩阵效率、上下文和共享节点负载影响, 不能直接按参数倍数预测; 本实验没有实际训练 C256/L3, 以上只是手算, 不能编造其耗时。

(3) 温度 $T \rightarrow 0$ 与 $T \rightarrow \infty$ 时, softmax 采样分别退化成什么? 什么任务适合低温、什么场景适合高温? 结合 exp6 的生成结果说明。

令温度为 τ 以免与上下文 T 混淆, $p_i = \exp(z_i/\tau) / \sum_j \exp(z_j/\tau)$ 。 $\tau \rightarrow 0^+$ 时概率集中于最大 logit, 唯一最大值时趋近贪心; 若并列最大, 则理想极限在并列项上均分。 $\tau \rightarrow \infty$ 时各有限 logit 趋于相等, 分布趋向均匀; 使用 top-k 后均匀化的范围是允许的候选集合, 而非必然整个词表。

低温适合希望稳定、格式较固定的输出, 但不会自动保证事实正确。高温可用于探索候选表达或创意草案, 代价是错误和不连贯增加。本次 0.5 组主要稳定续写原诗, 1.5 组出现更多错接, 说明提高随机性不能替代模型能力; 这些结论只针对本批样本。

(4) 字符级分词的优缺点各是什么? BPE 如何在“词表大小”与“序列长度”之间折中? 为什么真实 LLM 都用 BPE 类分词器?

字符级分词实现简单、词表小, 能清楚看到一个汉字对应一个索引, 适合本实验; 缺点是相同文本需要更多时间步, 词与短语的组合关系要由模型学习。当前固定词表对未见字符会报错, 也不能把“字符级”误解为天然支持所有输入。

BPE 逐步合并常见符号片段, 使常见词或子词用较少 token 表示, 而罕见词仍能拆成较小单位, 从而在词表大小与序列长度之间折中[3]。较大的词表增加嵌入和输出层成本, 却可能减少序列长度及注意力成本。真实语言模型常用子词分词, 但“都用 BPE”过于绝对: SentencePiece 也支持 Unigram 等方法[4]; 应根据语言、覆盖率和效率选择。

(5) 本实验是“从零、在数千字语料上训练”；真实 LLM 是“预训练（海量语料）+ 指令微调 + RLHF”。请从数据量、参数量、训练目标三方面比较两者，并回答：把本实验语料扩大 1000 倍，能得到一个“会聊天”的模型吗？为什么？

数据量方面，本实验只有 2163 字符且不断重复取窗口，训练 2000 步所见 8,192,000 个 token 不是同等规模的独立新语料。参数量为 502,656；GPT-3 原论文的最大模型为 1750 亿参数，使用大规模文本预训练[5]。模型规模差异不是唯一因素，数据覆盖范围和质量同样重要。

训练目标方面，本实验仅优化下一字符交叉熵，学习诗句续接；真实系统通常先进行大规模语言建模，再通过指令示例和偏好反馈等方式提升任务遵循能力。InstructGPT 展示了监督微调与人类反馈强化学习的流程[6]，但并非所有系统都采用完全相同的后训练方法。

把语料扩大 1000 倍约为 216.3 万字符。如果只是复制原语料，几乎不增加信息；即使新增同体裁诗文，也不自然提供多轮对话、指令理解和知识覆盖。还需要合适的数据分布、模型容量、训练预算及对话评价，因此仅扩大数量不能保证得到会聊天的模型。

(6) 回顾与 Codex 协作实现 CausalSelfAttention 的过程：AI 在哪些环节最有价值？哪些地方必须读懂公式才能改对（因果掩码、多头 reshape、权重共享）？

本次 Codex 在把指南转为可运行实现、检查张量形状、补充测试和定位工程故障上最有价值。协作详情见第 6 节。判断这些输出是否正确，不能只凭程序能运行或 loss 下降；需要把公式、代码与测试对应起来。

因果掩码应将未来位置的注意力分数在 softmax 前填为 $-\infty$ ，使其概率为 0；若填 0，未来位置仍可能得到非零概率。Q/K/V 从(B,T,C)先变为(B,T,H,C/H)，再交换时间与头轴成为(B,H,T,C/H)，注意力在时间轴上计算，拼回时逆向变换。交换错误可能形状仍合法却改变计算含义。

权重共享应使输出 head.weight 与 tok_emb.weight 指向同一 Parameter，仅复制数值不能保证训练中继续共享；参数计数也只能计一次。当前测试核对了共享对象、精确参数量、未来 token 对过去输出及梯度的影响，并对有无位置嵌入均检查因果性。这些检查比仅观察生成几句顺眼的诗更能定位实现错误。

附录 复核记录与提交材料

以下图像直接排版本机实际执行的参数核对输出，保留真实数值，不模拟 IDE 界面。

```
Actual local CPU execution: MiniGPT(699, Config())
token_embedding: 89472
position_embedding: 16384
per_block: 198272
final_layernorm: 256
approximate: 499072
exact: 502656
approximation_relative_error: 0.0071301247771836
sum(p.numel() for p in model.parameters()): 502656
head.weight is tok_emb.weight: True
```

图 8 参数计数与权重共享实际输出

最终复核：6 项行为测试全部通过；47 项必要产物完整且哈希一致；9 个最终模型与 1000 步快照 CPU 重放通过，9 模型最大固定窗口 loss 绝对偏差约 1.15×10^{-7} ；58 段原始样本长度、词表和 TXT/JSON 一致，六组采样统计独立重算一致。语料与指南逐字匹配。

复现边界：正式生成使用 PyTorch2.6.0，本机核验使用 2.14.0；同种子不保证跨版本逐字生成相同文本。本报告引用原始 HPC 生成文件，不用本机重生成结果替换原文。HPC 作业 10765 已 COMPLETED，退出码 0:0；队列检查为空，资源已释放，报告阶段没有新建训练作业。

复核入口：python -m unittest test_min_llm -v；python analyze_results.py --verify-only。代码与原始结果基准提交 e01c944；最终报告、质量评级及本次核验记录放入 lab03/report。本地按前两次实验架构，提交材料存正式报告，lab03_min_llm 保存代码与结果，tools 保存报告构建与检查文件。

仓库：<https://github.com/s-max-oss/llm-course-labs/tree/main/lab03>

参考资料

- [1] 课程资料：《作业三_手搓最小 LLM_使用 CPU 训练_实验指南》及实验报告样板。
- [2] Haviv A, et al. Transformer Language Models without Positional Encodings Still Learn Positional Information. Findings of EMNLP, 2022. <https://arxiv.org/abs/2203.16634>
- [3] Sennrich R, Haddow B, Birch A. Neural Machine Translation of Rare Words with Subword Units. ACL, 2016. <https://arxiv.org/abs/1508.07909>
- [4] Kudo T, Richardson J. SentencePiece: A simple and language independent subword tokenizer and detokenizer for Neural Text Processing. EMNLP, 2018. <https://arxiv.org/abs/1808.06226>
- [5] Brown T, et al. Language Models are Few-Shot Learners. NeurIPS, 2020. <https://arxiv.org/abs/2005.14165>
- [6] Ouyang L, et al. Training language models to follow instructions with human feedback. NeurIPS, 2022. <https://arxiv.org/abs/2203.02155>
- [7] Vaswani A, et al. Attention Is All You Need. NeurIPS, 2017. <https://arxiv.org/abs/1706.03762>