

《人工智能——深度学习大模型智能体》

实验报告

实验作业四

Vector RAG、GraphRAG 与 WikiRAG

对比实验

姓 名：孙驰

学 号：2024311281

班 级：计算机 10 班

完成日期：2026 年 10 月 3 日

基于同一校园语料的检索评测与来源核查

使用本地真实中文嵌入模型，比较向量、图谱与条目化知识的证据覆盖；记录窗口扫描、失败例与可复核的原始结果。忠实度评分由本人参考 AI 理由后确认。

1 实验概述

1.1 实验目的

本实验在指南提供的 15 篇虚构校园文档上实现 Vector RAG、GraphRAG 与 WikiRAG，保持同一嵌入模型、问题集和文档级评价口径，比较事实、多跳与全局问题。20 题结果中，Vector 平均 Recall@5 为 0.9667，Graph Local 为 0.8083，Wiki 为 0.8583；图谱并未全面优于向量检索。

实验重点是观察知识组织如何影响证据获取：桥接文档可能相关性低，图的连通性与实体名称会限制多跳展开，条目化会改变事实粒度与来源顺序。通过 K 扫描、Local/Global 对照、来源修正和 RRF 选做，区分排序、覆盖、忠实度与答题完整性。

在参考知识库评测之后，使用本人提供的 DeepSeek API 追加实际答案生成、三元组抽取、社区摘要和 Wiki 条目构建。原基线保持不变；新知识库另行评测并审计生成错误，九例评分由本人参考 AI 初评理由后确认。

1.2 实验环境

表 1 实验环境清单

类别	名称 / 版本	备注
操作系统	Windows 10.0.26300	本机 CPU，未申请 HPC 资源
Python / 基础库	3.11.16; torch 2.14.0; numpy 2.4.6	CPU 四线程; NetworkX 3.6.1
嵌入与绘图库	sentence-transformers 6.1.0; transformers 5.18.0	Matplotlib 3.11.1
嵌入模型	BAAI/bge-small-zh-v1.5, 512 维	指南允许的中文本地替代模型; 真实神经嵌入
LLM API	deepseek-flash; temperature=0; 关闭 thinking	61 次真实调用; 本人参考同模型初评确认评分
修改处	chunk_docs / metrics / evaluate / GraphRAG / WikiRAG	显式传 scope、文档去重、路径边界、缓存、来源核查
新增与选做	Q16—Q20; 实体归一; Hybrid RRF	基线保留原文、40 三元组、9 条目及指南 gold

模型版本固定为 7999e1d3359715c523056ef9478215996d62a620，经镜像下载后本地推理。所有表示单位归一化；仅查询加“为这个句子生成表示以用于检索相关文章：”，文档不加。余弦值用于相对排序，不当作概率。[2]

完整逐题记录和 92 个实际 512 维向量随结果保存，独立重编码最大向量差约 1.45×10^{-7} 。逻辑测试的 char3 后端需显式选择，正式套件拒绝该后端，模型加载失败不会自动替换成字符向量。

2 三种 RAG 系统实现

2.1 Vector RAG 基线

配置：块长 120 中文字符，重叠 20，步长 100，Top-K=5。末块不足 120 字符时原样保留，覆盖到原文末尾就停止，不产生多余空块。索引先按块余弦排序，再按文档号去重，取前 K 篇文档。

本语料的 15 篇文档都短于 120 字符，实际形成 15 块。因此重叠参数已实现，但本次没有实际跨块重叠；不能用当前结果证明长文档分块策略优劣。

Q01 《大模型通识课》授课教师所在学院的行政负责人是谁？

实际保存检索结果排版 | 余弦相似度 | 归一化 BGE 512维

1. doc06 cosine=0.633221 字符区间[0,62)

《大模型通识课》课程代码 AI2101, 3 学分、32 学时, 春季学期开设, ...

2. doc04 cosine=0.563587 字符区间[0,94)

人工智能学院教师：李文瀚，教授，2019 年入职，研究方向为检索增强生成，主...

3. doc05 cosine=0.496930 字符区间[0,45)

计算机学院教师：周天宇，教授，研究方向为分布式系统；林小雨，副教授，研究方向...

4. doc02 cosine=0.472049 字符区间[0,56)

人工智能学院成立于 2018 年，首任及现任院长为王启明教授。学院下设机器学...

5. doc08 cosine=0.453842 字符区间[0,76)

选课规则：本科生每学期最多修 30 学分；GPA 低于 2.0 给予学术警告...

图 1 Q01 实际检索结果排版 文档号 分数与原文摘录

Q01 前三名为 doc06、doc04、doc05，院长所在 doc02 排第 4。K=5 覆盖全部三篇 gold；K=3 缺院长证据。图中内容来自保存的实际输出，以便阅读而排版，没有模拟终端或 IDE 界面。

2.2 GraphRAG（三元组 + 图 + 社区）

使用 NetworkX MultiDiGraph 保留不同关系及来源，完整图 45 节点、40 条三元组。将图投影为无向图，采用 greedy modularity 得到 10 个社区。Global 查询使用指南预置的 3 段主题摘要；这些摘要并非根据本次 10 个社区现场生成。当前实现是教学简化版。

Local 最多匹配 2 个实体，从入边与出边双向展开；最多 3 跳、每轮前沿最多 6 节点，节点与三元组边分别去重，稳定处理同分项。候选三元组按余弦排名，文档分数等价于该文档候选边的最大分数。没有匹配边时回退 Global，并记录 fallback。

上述 40 三元组与 3 段预置摘要用于参考基线；现场版本另由 15 篇原文抽出 65 条归一三元组、73 节点、14 社区，并对每个实际社区生成摘要，不替换参考图。社区来源仅取内部边所关联的文档。

头实体	关系	尾实体	来源
李文瀚	主讲	大模型通识课	doc06
李文瀚	任职于	人工智能学院	doc04
人工智能学院	院长	王启明	doc02
李文瀚	研究方向	检索增强生成	doc04
AI 协会	指导教师	李文瀚	doc11

Q01 实际图中的子图 | 完整图 45 节点 / 40 三元组
沿入边找到教师，第二跳到学院，第三跳取得院长来源




图 2 完整知识图谱中的 Q01 关系子图

实际 Q01 只匹配“大模型通识课”：第 1 跳沿李文瀚主讲课程的入边得到 doc06，第 2 跳李文瀚任职于人工智能学院得到 doc04，第 3 跳学院院长得到 doc02。最终文档顺序为 doc06、doc02、doc04、doc11、doc10，全证据命中。

默认保留严格子串匹配作为基线。另用空格、书名号归一及“云大→云山大学”别名做诊断：Q02 的 AI 协会由无匹配变为 AI 协会；归一后补回 doc11。去空格只能解决词面问题，不能自动处理重名教师或实体歧义。

2.3 WikiRAG（条目化知识库）

保留指南 9 个条目，平均正文长度为 74.4444 字符。正文嵌入相似度取 Top-3 条目，按相似度及来源列表顺序展开，再做文档去重。标题用于展示，不额外加入正文向量；条目预算 3 与文档预算 K 独立。

例如“人工智能学院”聚合 doc02 的院长和系、doc10 的重点实验室、doc15 的联合培养。条目减少跨文档阅读，但学院条目不含教师研究方向，校园条目省略校巴频率等细节；它还加入了原文没有的联合培养人数和教材名称。

现场 Wiki 沿用这 9 个主题及来源列表，正文全部由 DeepSeek 重新生成。这样可以比较条目文本改变后的排序，同时保留来源选择的影响；并非自动发现新主题或从全部语料自由建条目。

预置条目原文与来源（保留参考数据，另做修正对照）

[人工智能学院] sources: doc02, doc10, doc15
人工智能学院成立于 2018 年，院长王启明教授，下设机器学习系、智能科学系、认知计算系。认知计算全国重点实验室依托本院建设。与新加坡南洋理工大学有本科联合培养项目（每年 15 人）。

[大模型通识课] sources: doc06
《大模型通识课》（AI2101）：3 学分 32 学时，春季学期开设，李文瀚主讲，面向全校本科生，无先修要求，教材《人工智能——深度学习大模型智能体》。

来源核查：doc15未写“每年15人”；doc06未写教材名称。
条目重写能聚合关系，也会遗漏原文细节或加入无依据内容。

图 3 参考条目原文 聚合来源与核查结果

主实验保留参考数据以便对照指南，修正版只移除无依据的信息并修正关系，不改原文或 gold。生成示例仅使用检索返回的原始文档，不把这些条目增写直接当作事实；这样能核查原文，但不能说明预置条目本身已经忠实。

3 对比实验设计

内置 15 题各类型 5 题；增加 5 题覆盖事实、多跳和全局，合计事实 6、多跳 7、全局 7。新增题在评测前固定证据，不根据排名修改 gold。三范式共享模型、问题文本和文档级 K=5；Graph 分别运行 Local 与 Global，避免把 scope 参数遗漏后得到相同路径。

Recall@K=命中的 gold 文档数÷gold 文档总数，逐题宏平均。MRR 先对返回文档去重，取前 K 篇中第一篇相关文档的排名 r，记 1/r；完全未命中记 0。条目、块和三元组都不是最终评价单位。

表 2 内置题示例与全部五道新增题

编号	类型	问题	evidence
Q01	多跳	《大模型通识课》授课教师所在学院的行政负责人是谁？	doc04, doc06, doc02
Q06	事实	云山大学的校训是什么？	doc01
Q11	全局	云山大学有哪些科研平台？分别依托谁建设？	doc10, doc02, doc03
Q16	事实	校内校巴共有几条线路，多久一班？	doc14
Q17	多跳	研究知识图谱的教师所授课程要求先修什么课程？	doc04, doc07, doc08
Q18	多跳	机器人战队指导教师所在学院下设哪些系？	doc11, doc04, doc02
Q19	全局	学校在图书资源和国际交流方面有哪些安排？	doc13, doc15
Q20	全局	两所学院分别开设哪些本科专业或下属系，负责人是谁？	doc02, doc03

新增证据依据：Q16 用 doc14 核查校巴线路和频率；Q17 以 doc04 教师研究方向→doc07 授课→doc08 先修规则关联；Q18 以 doc11 社团指导→doc04 任职→doc02 学院下设系关联；Q19 聚合 doc13 图书资源与 doc15 国际交流；Q20 比较 doc02/doc03 两学院的组织和负责人。完整 20 题见附录。

Q11 沿用指南 gold doc10、doc02、doc03，但科研平台及依托关系主要已写在 doc10。金标准覆盖不足不一定代表无法答题；后续同时展示原文支持、证据覆盖和答案是否完整。

4 实验结果与数据记录

4.1 检索质量 (Recall@5 与 MRR)

表 3 三范式 × 三类问题检索结果 (20 题)

范式	fact Recall	fact MRR	multi Recall	multi MRR	global Recall	global MRR
Vector	1.0000	1.0000	1.0000	1.0000	0.9048	1.0000
Graph Local	0.8333	0.8333	0.9524	0.9286	0.6429	0.4690
Graph Global	0.5000	0.3889	0.8333	0.7143	0.7857	0.6119
Wiki	1.0000	0.6944	0.9524	1.0000	0.6429	0.5476

表 3 统一为 20 题、文档 K=5。Vector 在事实与多跳题上 Recall 及 MRR 均为 1；全局 Recall 为 0.9048。Graph Global 的全局 Recall 为 0.7857，高于 Local 的 0.6429，但其事实 Recall 只有 0.5000。Wiki 事实 Recall 为 1，MRR 仅 0.6944，说明来源展开顺序让答案文档排得较晚。

表 3a 全题宏平均与全证据命中

方案	Recall@5	MRR	全证据命中
Vector	0.9667	1.0000	19/20
Graph Local	0.8083	0.7392	14/20
Graph Global	0.7167	0.5808	11/20
Wiki	0.8583	0.7500	16/20

本语料只有 15 篇短文；Vector 的高分与 BGE 中文匹配及小检索空间有关，不代表一般场景下向量检索必然最优。Graph Local 包含无实体匹配时的 Global 回退，其汇总不能被解释为所有题都依靠局部走边成功。

所有逐题返回文档、分数、路径、未命中证据保存于 eval20_local/global.json。未改成按问题类型自动选择 Graph 模式，也未依据 gold 挑选更好结果。

4.2 窗口敏感性（Top-K 扫描，任务四⑤）

表 4 不同 Top-K 下三类问题的 Recall（内置 15 题）

范式	类型	K=1	K=2	K=3	K=5
Vector	事实	1.0000	1.0000	1.0000	1.0000
Vector	多跳	0.4333	0.8000	0.8667	1.0000
Vector	全局	0.7667	0.7667	0.7667	0.8667
Graph Local	事实	1.0000	1.0000	1.0000	1.0000
Graph Local	多跳	0.3667	0.8000	0.9333	0.9333
Graph Local	全局	0.2000	0.4000	0.5000	0.7000
Graph Global	事实	0.4000	0.4000	0.6000	0.6000
Graph Global	多跳	0.1667	0.5000	0.7333	0.8333
Graph Global	全局	0.2667	0.5333	0.7000	0.9000
Wiki	事实	0.6000	0.8000	1.0000	1.0000
Wiki	多跳	0.4333	0.7000	0.8667	0.9333
Wiki	全局	0.3000	0.5000	0.6000	0.6000




图 4 真实嵌入的窗口扫描 每类型五题

K 扫描只用内置 15 题，每类型 5 题，与表 3 的 20 题分开。多跳 gold 有 2—3 篇文档，K=1 结构上不能拿满。例如 Vector 多跳 Recall 从 K=5 的 1.0000 降为 K=1 的 0.4333，降幅 0.5667，是该范式最大降幅。Wiki 全局在 K=3 和 5 均为 0.6000，说明仅扩大文档窗口不能补回未进入 Top-3 的条目。

4.3 忠实度评分（每范式抽 3 题）

表 5 忠实度 AI 初评与本人确认评分

Q01（多跳）、Q06（事实）、Q11（全局）各由三范式回答，共 3 题×3 范式=9 个答案样例，符合“每范式抽 3 题”。跨范式问题构成配对对照，只覆盖三个独立问题。本人参考 AI 初评理由确认均为 5 分，未开展独立盲审。原答案与声明见 results/live_api/answer_review.json，调用见 calls/；当前确认分数见 report/human_scores.json。

范式	题号	AI / 本人	回答要点摘录	声明核查 / 完整性
Vector	Q01	5 / 5	授课教师是李文瀚[doc06]，他属于人工智能学院[doc04]；院长为王启明[doc02]。	3/3 条受支持；已回答
Vector	Q06	5 / 5	校训是「格物致知」[doc01]。	1/1 条受支持；已回答
Vector	Q11	5 / 5	全国重点实验室依托人工智能学院；超算中心由大学与省科技厅共建，计算机学院参与运行管理[doc10]。	4/4 条受支持；已回答
Graph Local	Q01	5 / 5	李文瀚[doc06]属于人工智能学院[doc04]；院长为王启明[doc02]。	3/3 条受支持；已回答
Graph Local	Q06	5 / 5	校训是「格物致知」[doc01]。	1/1 条受支持；已回答
Graph Local	Q11	5 / 5	资料中没有科研平台及其依托单位信息，无法回答[doc01]。	AI 拆分 0 条；拒答
WikiRAG	Q01	5 / 5	未提供授课教师所在学院（人工智能学院）的行政负责人，无法回答[doc06][doc04]。	AI 漏拆学院事实；院长未回答
WikiRAG	Q06	5 / 5	校训是「格物致知」[doc01]。	1/1 条受支持；已回答
WikiRAG	Q11	5 / 5	资料中没有科研平台及其依托单位信息，无法回答[doc01][doc04][doc11][doc12][doc14]。	AI 拆分 0 条；拒答

量表：5=事实受支持或谨慎拒答，4=边界含糊，3=部分无依据，2=多项无依据，1=主要无依据。九例 AI 初评均 5；引文均能在对应原文中找到，但引文匹配不等于逻辑支持，且高分不等于答案完整。

Graph/Wiki Q11 拒答，无事实声明时支持比例分母为 0，不定义。Wiki Q01 虽然拒答，却在括号中断言学院为人工智能学院；同模型评审错误地给出 claims=[]，审计指出漏拆，该事实受 doc04 支持。评分确认不消除这一评审错误。抽样结论限于三题；本次未计算平均忠实度，也未运行 RAGAS。

4.4 工程账对比

表 6 三范式构建与更新成本

范式	本次实际构建	新增一篇文档的变更	时间口径
Vector	分块、BGE 编码、向量矩阵	编码新增块并追加索引；原文修改时替换相关块	索引 0.1509 秒
Graph	载入 40 参考三元组、建图、检测社区，编码三元组及 3 摘要	校验三元组、合并实体；更新受影响社区与摘要，再编码	索引 0.1520 秒
Wiki	载入 9 参考条目与来源，编码正文	定位并重写相关条目、核查来源与冲突，再编码	索引 0.0889 秒

索引计时不含下载、7.59 秒模型加载、人工整理、关系抽取或改写。未做新增文档计时，更新栏只列所需步骤；预热与缓存也会影响秒数，不能据此判断生产成本。三种范式的增量维护区别见思考题 4。

4.5 MRR 手算验证（必做）

选题在查看排名前固定为 Q01、Q06、Q11，包含多跳题。0 表示 Top-5 未命中，倒数贡献为 0 而非 1/0；以下均按原始返回的文档级顺序计算。

表 7 MRR 手算与脚本核对

范式 / 题号	首次排名	1/rank 或 0	脚本核对
Vector / Q01	1	1.0000	一致
Vector / Q06	1	1.0000	一致
Vector / Q11	1	1.0000	一致
GraphRAG / Q01	1	1.0000	一致
GraphRAG / Q06	1	1.0000	一致
GraphRAG / Q11	0 未命中	0.0000	一致
WikiRAG / Q01	1	1.0000	一致
WikiRAG / Q06	1	1.0000	一致
WikiRAG / Q11	0 未命中	0.0000	一致

Vector: $(1+1+1)/3=1.000000$ ；Graph Local: $(1+1+0)/3=0.666667$ ；Wiki: $(1+1+0)/3=0.666667$ 。分别用 `--mrr_check 1,1,1` 与 `--mrr_check 1,1,0` 复核，与 `mrr_manual.json` 一致。手算这 3 题的均值不是表 3 或表 3a 全 20 题 MRR。

5 结果分析

5.1 分问题类型分析

在本次 20 题上，Vector 各类型 Recall 最高或并列最高，事实与多跳全部 gold 命中。多跳题的向量弱点主要在窗口收窄时显现：Q01 的课程和教师语义贴近问题，但院长的桥接文档 doc02 排第 4。Graph 能沿教师、学院、院长关系取得 doc02，但其效果依赖实体匹配和图连通性。

对全局题，Graph Global 比 Local 更适合聚合多个主题；Q11 Local 仅返回 doc01 中的大学基本信息边，Global 摘要却含院系和平台来源，使 Recall 从 0 恢复到 1。Wiki 依靠条目重写聚合资料，但 Top-3 条目筛选和来源列表先后会限制覆盖；扩大 K 未必能解决上游条目漏选。

Recall 描述证据是否齐全，MRR 只看首个相关文档来得早不早。Vector Q11 第 1 名 doc10 已支持完整平台事实，但 gold doc02/doc03 缺失，所以 $MRR=1$ 、 $Recall=1/3$ 。需要结合 gold 合理性、上下文内容与答案核查，不能只看单一指标。

5.1.1 选做 RRF 与来源修正对照

选做使用中文字符 bigram 词面余弦排名与稠密排名，按

$RRF=1/(60+r_dense)+1/(60+r_sparse)$ 融合。20 题事实 Recall 与 MRR 均保持 1.0000；全题 Recall 从 0.9667 降为 0.9583，MRR 从 1.0000 降为 0.9750，全证据命中由 19 降至 18 题。此负结果保留，不能写成混合检索必然提升。

单独修正三处来源问题后，Graph Local 全题 Recall/MRR 仍为 0.8083/0.7392；Wiki 变为 0.8417/0.7417，低于参考 0.8583/0.7500。忠实改写会改变嵌入排序，检索分数略降不能成为保留无依据内容的理由。主实验不替换成择优结果。

5.1.2 现场 API 构建与复测

同一 15 篇原文、同一 BGE 版本、同一 20 题与文档 K=5。v2 先现场抽取，头尾去空格和书名号归一并保留来源；检测 14 社区，再按内部边及原文生成 14 段摘要。九个 Wiki 条目正文重新聚合。表 7a 展示新知识库，参考表 3/3a 原始数据完整保留。

官方 API 为 <https://api.deepseek.com/chat/completions>；请求与响应模型均 deepseek-flash。
[5] 共 61 次调用：9 答案、3 次 v1/15 次 v2 抽取、14 摘要、9 条目、2 现场 Q11 及 9 评审。
输入 15088、输出 3768、共 18856 token。整段 24.94 秒，最多三请求并行；单调用耗时之和 47.20 秒不等于运行总耗时，也不计入表 6。密钥只用于进程环境，不保存于代码或结果。

表 7a 实际 API 构建后的 20 题评测

现场方案	Recall@5	MRR	全证据命中
Vector 原文基线	0.9667	1.0000	19/20
Graph Local	0.8333	0.8167	15/20
Graph Global	0.9000	0.8375	16/20
Wiki	0.9083	0.7792	15/20

参考→现场：Graph Local Recall 0.8083→0.8333，MRR 0.7392→0.8167；Global Recall 0.7167→0.9000，MRR 0.5808→0.8375；Wiki Recall 0.8583→0.9083，MRR 0.7500→0.7792，但全证据命中 16→15 题。宏平均 Recall 提高并不保证每题更好。Vector 仍为 0.9667/1.0000、19/20，现场图谱仍未全面超过向量。

现场图谱同时改变三元组覆盖、表述、实体归一与摘要来源，不能把差异归因于单一提示词，也不是模型能力的控制变量实验。Global 的全局题 Recall/MRR 为 0.7619/0.7143；Local 为 0.5238/0.4762，后者低于参考 Local 全局 Recall 0.6429。

Q11 现场 Graph Global 返回 doc01/doc10/doc09，Wiki 返回 doc01/doc12/doc14/doc03/doc10，gold 覆盖分别 1/3 和 2/3。两份现场答案都正确给出两平台及管理关系，因为 doc10 已含主要事实；覆盖指标与答题完整性需分别核查。九例评分仍针对参考基线的上下文，不能移作现场全题生成成绩。

5.1.3 抽取提示词对照与生成错误

v1 只要求头实体、关系、尾实体和 JSON；v2 增加只抽原文、不补人数年份教材、区分共建与管理、全称与关系方向等约束。两版预先定义，v1 在 doc04/doc10/doc15 调用 3 次，v2 在全 15 篇调用 15 次；比较样本只有三个共同文档，不能声称根据本次 v1 输出又迭代优化了 v2。

表 7b 现场知识的原文审计

输出位置	实际观察	判断及影响
doc04 v1→v2	v1 含 9 条；v2 含 5 条，增加三位教师任职学院，漏掉研究方向、职称及 2019 年	补入多跳任职边但损失其他事实；v2 并非全面优于 v1
doc03 v2	计算机学院—设计→计算机科学与技术 / 软件工程	原文“设”专业，关系词误写；JSON 格式合格仍有语义错误
doc13 v2	只抽分馆位置与收藏，遗漏藏书 380 万、7:00—22:00 开放	图谱事实覆盖不完整，原文级检索命中可能掩盖该遗漏
社区 9 摘要	增写“馆藏与空间由图书馆统一建设”等管理安排	doc13 无依据；提示要求并未消除幻觉
社区 12 / 14 摘要	新增“课程共建与运行管理”“共建类合作”等分类	来源分别为 doc08 课程规则、doc15 国际交流；分类受提示词牵引，无直接依据
doc10 两版 / doc15 两版	doc10 均区分大学共建与学院管理；doc15 均使用“学校”实体	不能宣称 v2 修复 v1 的管理错误；泛指实体仍未与大学自动连通

上述原始错误保留在 extractions_v*.json 与 community_summaries.json。未经修正的现场索引仍用于表 7a，避免事后择优。来源审计见 live_knowledge_audit.json；抽取约束应按文档任务定制，泛用“共建/管理”措辞可能把无关事实引向错误分类。今后可分开验收结构、覆盖和语义，逐条回溯来源后再用于正式答案。

5.2 失败案例分析（每范式至少 2 例）

表 8 失败案例归因

范式 / 窗口	题号	真实返回 / 遗漏	原因
Vector K=5	Q11	doc10, doc01, doc04, doc11, doc05; 缺 doc02, doc03	平台原文 doc10 排第 1，但两学院背景 doc02/doc03 均未入 Top-5；保留指南 gold，语义排序未覆盖完整标注。
Vector K=3	Q01	doc06, doc04, doc05; 缺 doc02	桥接的学院院长 doc02 排第 4；K=3 时被计算机学院教师 doc05 挤出。K=5 恢复，并非 Top-5 失败。
GraphRAG K=5	Q02	doc02, doc04, doc06, doc07, doc08; 缺 doc11	AI 协会含空格，节点 AI 协会不含空格，未匹配实体而回退 Global；未返回 doc11。
GraphRAG K=5	Q11	doc01; 缺 doc02, doc03, doc10	只匹配云山大学，图中大学只连基本信息（均 doc01）；院系与平台子图未接入，局部走边只返回 doc01。Global 可补齐 gold。
WikiRAG K=5	Q01	doc06, doc04, doc11, doc05; 缺 doc02	Top-3 条目未选中人工智能学院，返回 doc06/doc04/doc11/doc05，缺少 doc02；条目数与文档 K 是两层预算。
WikiRAG K=5	Q13	doc02, doc10, doc15, doc11, doc13; 缺 doc04	学院教师条目未进 Top-3，学院条目并不含教师研究方向，doc04 遗漏。

Vector 的第二例明确来自 K=3：在 K=5 的 20 题中只有 Q11 未全证据命中。Graph Q02 是词面不匹配并触发回退；Q11 是关系链与学校节点未连通。Wiki 两例都是上游条目未选中，不能仅归咎于原文向量不好。

额外来源失败：Graph 三元组/摘要将计算机学院的“参与运行管理”改成“参与共建”；Wiki 增写“每年 15 人”及教材名称。前者改变责任关系，后两者原文无证据。来源审计保留对照并修正，而不是把预置数据当作天然无误的金标准。

6 AI 协作记录 任务分工与反馈

表 9 实验组织与 AI 辅助过程

序号	实验环节	我的参与	Codex 辅助与结果
1	任务规划	明确实验要求，提供课程资料，确定按指南与样板组织实验	梳理实现流程与评价指标，形成统一语料、模型和题集的对比方案
2	实施安排	确定协作方式，委托实现与检验，并提供补充试验所需的资源	实现三种 RAG 和复现脚本，保留参考基线及独立现场结果
3	资源支持	提供 DeepSeek 接口，支持现场生成和知识构建	完成 61 次实际调用，保存输出与用量；密钥不进入代码或报告
4	审阅与反馈	检查协作记录与样例选取，提出表述调整和评测设计核查要求	核对指南与对照方案，检查实现和来源；13 项测试通过，保留实际失败
5	评分确认	参考 AI 初评和理由，决定沿用九例忠实度分数	记录本人确认的九例 5 分，保留拒答、完整性及评审漏拆的区别
6	报告完善	明确模板、归档和提交要求，提出内容修改意见	整理分析、修改排版并同步材料，保留可复核结果

我负责明确实验要求、提供资料与接口，并对协作记录、样例选取和提交形式提出修改意见。Codex 据此辅助完成实现、运行、数据核对与报告整理。九例评分已由我参考 AI 初评理由确认，最终提交仍由我审核。

7 思考题作答

(1) 以 Q01 写出完整关系链，说明 Vector 与 Graph 获取多篇证据的机制。

完整关系链为：李文瀚—主讲→大模型通识课（doc06）；李文瀚—任职于→人工智能学院（doc04）；人工智能学院—院长→王启明（doc02）。查询从课程名开始，先沿入边找到教师，再到学院、院长。沿边获取的是候选证据，仍需核对关系方向和来源。

Vector 没有显式链约束，doc02 的院长资料与问题的课程名相似度较低。本次 doc02 排第 4，Top-5 实际取全，Top-3 才失败；不能为符合题面而声称 Vector 本次 Top-5 也漏了它。

Graph 的 3 跳展开取到 doc02，但若缺任职关系、实体匹配失败或前沿剪枝，仍可能断链。

(2) 设某 3 题首次命中排名分别为 2、1、4，MRR 是多少？另 3 题 Recall@5 均为 1.0 而 MRR 仅 0.4，两个指标分别在衡量什么？为什么必须一起看？

$MRR = (1/2 + 1/1 + 1/4) / 3 = 7/12 \approx 0.583333$ 。Recall@5=1 说明所需证据都在前 5 篇，MRR=0.4 说明第一篇相关证据平均来得不够早；例如首次排名 2、5、2， $MRR = (0.5 + 0.2 + 0.5) / 3 = 0.4$ 。

二者必须一起看：MRR 只关心第一次命中，漏掉链后段的必要文档也可能得 1；Recall 关心覆盖，却不反映答案文档排在第 1 还是第 5。手算与脚本应使用相同 K 和文档去重口径，未命中记 0。

(3) 全局问题（如 Q11「有哪些科研平台」）Vector RAG 会怎么失败？GraphRAG 的社区摘要为什么适合？WikiRAG 又靠什么机制解决？三者的本质差异是什么？

全局问题需要跨主题聚合。Vector 可能取到几个高度相关片段却遗漏较弱的院系背景；本次 Q11 命中 doc10，但 doc03 第 6、doc02 第 11，gold 覆盖只有 1/3。实际平台答案主要在 doc10，因此覆盖不足与答案是否可写是两层评价。

Graph Global 以预置主题摘要汇总来源，Q11 取得 doc02、doc03、doc10 等，全证据命中；Local 则因大学与平台子图未连接而失败。Wiki 通过主题条目把学院、实验室、国际项目重写在一起，理论上便于整体阅读，但本次 Q11 漏选平台相关条目而未命中 gold。三者分别按原文片段相似度、结构关系/社区摘要、主题化文本组织知识；摘要或条目还必须维护事实来源。

(4) 增量更新：学校新增一位教师。三种范式各自要改动什么（重算哪些块 / 图 / 条目）？从更新成本解释表 8-4 中三种范式的工程定位。

新增教师时，Vector 为新文档生成块向量并更新索引，原有文档不必全部重编码；若分块边界因编辑变化，替换受影响块。Graph 需抽取任职、研究与授课关系、确认是否同名同人、添加带来源的边；社区结构改变时需重新检测或更新受影响社区摘要。

Wiki 需把教师信息并入学院教师或课程等主题，检查旧事实冲突并保留新来源，再更新这些条目向量。本代码尚未实现持久化增量维护，当前只是重新构建小索引；表 6 描述增量工作的工程定位，不宣称已实现生产级更新接口。

(5) 忠实度人工评分的主观性如何缓解？RAGAS 用 LLM 自动评忠实度的思路是什么（式 8-8），这种「用 LLM 评 LLM」又引入了什么新偏差？

人工评分可用统一量表、隐藏范式名称、先拆原子事实并逐条标注来源，再由两人独立评分讨论分歧。还需记录完整性：拒答可能忠实却未解决问题；没有事实声明时支持比例不定义，但不能把含事实的拒答错误地算成零声明。

按教材式 8-8，自动评审先拆事实，再核对能否由检索上下文推出，支持声明数÷总声明数为忠实度比例；RAGAS 采用此类 LLM 辅助检查思路。[4] 本次 DeepSeek 同模型初评九例均为 5 分，审计发现 Wiki Q01 漏拆学院声明，说明初评仍会拆分出错，自评偏差是待复核风险。本人参考 AI 初评理由确认评分，未开展独立盲审；固定提示、核查引用和独立复评可减轻偏差。本次未运行 RAGAS。

(6) GraphRAG 的抽取提示词与代码审查中有哪些关键检查？

本次有两版实际抽取提示词：v1 只要求三元组与 JSON；v2 要求原文支持、完整机构名称、明确方向，禁止补人数年份教材、混淆管理与共建。两版预先定义，doc04/doc10/doc15 有同文对照；没有依据本次输出继续修改提示词。doc04 的 v2 补回任职关系但漏掉研究方向，doc10 两版均正确区分管理；因此不能声称加强约束就必然提高全部事实覆盖。

代码审查分三层：JSON 用 `json.loads` 不用 `eval`，字段为三个非空字符串；来源存在且可追溯；每条关系语义与方向对照原文。doc03“设”变“设计”就是第三层失败。归一还需处理泛指“学校”和同名歧义，简单去空格不足以实体消歧。检索须限制深度/前沿、去重节点与边、记录回退并实传 `global`；API 需区分失败/截断、隔离密钥、保留请求和响应，评审不得越出返回上下文。

附录 全部问题与复核记录

表 A1 全部 20 题与固定 gold

编号	类型	问题	evidence
Q01	多跳	《大模型通识课》授课教师所在学院的行政负责人是谁？	doc04, doc06, doc02
Q02	多跳	AI 协会的指导教师主讲课程的课程代码是什么？	doc11, doc04, doc06
Q03	多跳	认知计算全国重点实验室依托的学院成立于哪一年？	doc10, doc02
Q04	多跳	《知识图谱导论》授课教师的研究方向是什么？	doc07, doc04
Q05	多跳	机器人战队的指导教师的研究方向是什么？	doc11, doc04
Q06	事实	云山大学的校训是什么？	doc01
Q07	事实	国家奖学金的金额是多少？	doc09
Q08	事实	图书馆每天几点到几点开放？	doc13
Q09	事实	人工智能学院成立于哪一年？	doc02
Q10	事实	春季学期什么时候开学？	doc12
Q11	全局	云山大学有哪些科研平台？分别依托谁建设？	doc10, doc02, doc03
Q12	全局	学校的学生奖励体系包含哪些项目？	doc09
Q13	全局	人工智能学院有哪些教师？各自做什么研究方向？	doc04
Q14	全局	本科生选课有哪些限制和先修要求？	doc08
Q15	全局	对想深入学习大模型的学生，学校提供哪些课程和课外活动？	doc06, doc11
Q16	事实	校内校巴共有几条线路，多久一班？	doc14
Q17	多跳	研究知识图谱的教师所授课程要求先修什么课程？	doc04, doc07, doc08
Q18	多跳	机器人战队指导教师所在学院下设哪些系？	doc11, doc04, doc02
Q19	全局	学校在图书资源和国际交流方面有哪些安排？	doc13, doc15
Q20	全局	两所学院分别开设哪些本科专业或下属系，负责人是谁？	doc02, doc03

独立复核：原 7 项逻辑测试与新增 6 项 API 离线边界测试均通过；19 组实验共 730 条逐题结果、180 条汇总指标与完整检索对象离线回放一致；4 条实体归一诊断与 3 组 MRR 核对一致。指定 BGE 本地权重重新编码 92 个文本，最大差约 1.45×10^{-7} ，确认正式结果来自真实模型。

复现入口：python run_experiments.py --revision

7999e1d3359715c523056ef9478215996d62a620 --output results_reproduced; python -m unittest test_hw4_rag -v; python analyze_results.py --verify-only。结果 manifest、环境、原文、逐题记录和向量均保留。模型权重、缓存、虚拟环境不进入 Git。

本地依照实验一至三的文件结构：提交材料保存正式报告，lab04_rag 保存代码、原始结果与报告副本，tools 保存构建与排版核验。Git 规范目录为 labs_repo/lab04。实验四未连接 HPC、未启动远程作业。现场 DeepSeek 补充的 61 份调用、输入/输出、使用量和知识构建结果另存 results/live_api；现场指标、缓存向量回放及来源审计独立核验。复现：python deepseek_live.py experiment；密钥从 DEEPSEEK_API_KEY 进程环境读取，勿写入命令或提交文件。九例忠实度分数已由本人参考 AI 初评理由确认均为 5 分，确认方式与分数另存 report/human_scores.json；原 API 结果保留生成时的待确认字段，供历史复核。

仓库：<https://github.com/s-max-oss/llm-course-labs/tree/main/lab04>

现场独立复核另覆盖 10 组实验、480 条逐题记录、120 个汇总及 123×512 维向量回放；BGE 离线重新编码最大差约 1.45×10^{-7} 。source_at_run.py 保留实际运行源码，其哈希与 run_summary 一致；之后仅强化三项评审字段类型检查，未改写原始调用结果。

参考资料

[1] 课程资料：作业四实验指南、更新后的实验报告样板；Lesson08 第八章，特别是式 8-6、8-8 至 8-10。

[2] BAAI. bge-small-zh-v1.5 官方模型卡。<https://huggingface.co/BAAI/bge-small-zh-v1.5>（512 维与查询指令）

[3] Sentence Transformers 模型 API 文档；NetworkX greedy_modularity_communities 官方文档。
https://sbert.net/docs/package_reference/sentence_transformer/model.html ;
https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.community.modularity_max.greedy_modularity_communities.html

[4] Es S, et al. RAGAS Automated Evaluation of Retrieval Augmented Generation. EACL 2024 Demonstrations. <https://aclanthology.org/2024.eacl-demo.16/>

[5] DeepSeek 官方 API 与 JSON Output 说明。<https://api-docs.deepseek.com/> ; https://api-docs.deepseek.com/guides/json_mode/（2026 年 10 月 3 日核查；模型请求及响应名以实际记录为准）