

《人工智能——深度学习大模型智能体》

实验报告

实验作业四

Vector RAG、GraphRAG 与 WikiRAG

对比实验

姓 名：孙驰

学 号：2024311281

班 级：计算机 10 班

完成日期：2026 年 10 月 3 日

基于同一校园语料的检索评测与来源核查

使用本地真实中文嵌入模型，比较向量、图谱与条目化知识的证据覆盖；记录窗口扫描、失败例与可复核的原始结果。人工忠实度评分待确认。

1 实验概述

1.1 实验目的

本实验在指南提供的 15 篇虚构校园文档上实现 Vector RAG、GraphRAG 与 WikiRAG，保持同一嵌入模型、问题集和文档级评价口径，比较事实、多跳与全局问题。20 题结果中，Vector 平均 Recall@5 为 0.9667，Graph Local 为 0.8083，Wiki 为 0.8583；图谱并未全面优于向量检索。

实验重点是观察知识组织如何影响证据获取：桥接文档可能相关性低，图的连通性与实体名称会限制多跳展开，条目化会改变事实粒度与来源顺序。通过 K 扫描、Local/Global 对照、来源修正和 RRF 选做，区分排序、覆盖、忠实度与答题完整性。

1.2 实验环境

表 1 实验环境清单

类别	名称 / 版本	备注
操作系统	Windows 10.0.26300	本机 CPU，未申请 HPC 资源
Python / 基础库	3.11.16; torch 2.14.0; numpy 2.4.6	CPU 四线程; NetworkX 3.6.1
嵌入与绘图库	sentence-transformers 6.1.0; transformers 5.18.0	Matplotlib 3.11.1
嵌入模型	BAAI/bge-small-zh-v1.5, 512 维	指南允许的中文本地替代模型; 真实神经嵌入
LLM API	仅检索评测; 无生成 API 调用	Codex 一次性整理九个有来源答案, 评分是 AI 初评
修改处	chunk_docs / metrics / evaluate / GraphRAG / WikiRAG	显式传 scope、文档去重、路径边界、缓存、来源核查
新增与选做	Q16—Q20; 实体归一; Hybrid RRF	基线保留原文、40 三元组、9 条目及指南 gold

模型版本固定为 7999e1d3359715c523056ef9478215996d62a620，经镜像下载后本地推理。所有表示单位归一化；仅查询加“为这个句子生成表示以用于检索相关文章：”，文档不加。余弦值用于相对排序，不当作概率。[2]

完整逐题记录和 92 个实际 512 维向量随结果保存，独立重编码最大向量差约 1.45×10^{-7} 。逻辑测试的 char3 后端需显式选择，正式套件拒绝该后端，模型加载失败不会自动替换成字符向量。

2 三种 RAG 系统实现

2.1 Vector RAG 基线

配置：块长 120 中文字符，重叠 20，步长 100，Top-K=5。末块不足 120 字符时原样保留，覆盖到原文末尾就停止，不产生多余空块。索引先按块余弦排序，再按文档号去重，取前 K 篇文档。

本语料的 15 篇文档都短于 120 字符，实际形成 15 块。因此重叠参数已实现，但本次没有实际跨块重叠；不能用当前结果证明长文档分块策略优劣。

Q01 《大模型通识课》授课教师所在学院的行政负责人是谁？

实际保存检索结果排版 | 余弦相似度 | 归一化 BGE 512维

1. doc06 cosine=0.633221 字符区间[0,62)

《大模型通识课》课程代码 AI2101, 3 学分、32 学时, 春季学期开设, ...

2. doc04 cosine=0.563587 字符区间[0,94)

人工智能学院教师：李文瀚，教授，2019 年入职，研究方向为检索增强生成，主...

3. doc05 cosine=0.496930 字符区间[0,45)

计算机学院教师：周天宇，教授，研究方向为分布式系统；林小雨，副教授，研究方向...

4. doc02 cosine=0.472049 字符区间[0,56)

人工智能学院成立于 2018 年，首任及现任院长为王启明教授。学院下设机器学...

5. doc08 cosine=0.453842 字符区间[0,76)

选课规则：本科生每学期最多修 30 学分；GPA 低于 2.0 给予学术警告...

图 1 Q01 实际检索结果排版 文档号 分数与原文摘录

Q01 前三名为 doc06、doc04、doc05，院长所在 doc02 排第 4。K=5 覆盖全部三篇 gold；K=3 缺院长证据。图中内容来自保存的实际输出，以便阅读而排版，没有模拟终端或 IDE 界面。

2.2 GraphRAG（三元组 + 图 + 社区）

使用 NetworkX MultiDiGraph 保留不同关系及来源，完整图 45 节点、40 条三元组。将图投影为无向图，采用 greedy modularity 得到 10 个社区。Global 查询使用指南预置的 3 段主题摘要；这些摘要并非根据本次 10 个社区现场生成。当前实现是教学简化版。

Local 最多匹配 2 个实体，从入边与出边双向展开；最多 3 跳、每轮前沿最多 6 节点，节点与三元组边分别去重，稳定处理同分项。候选三元组按余弦排名，文档分数等价于该文档候选边的最大分数。没有匹配边时回退 Global，并记录 fallback。

头实体	关系	尾实体	来源
李文瀚	主讲	大模型通识课	doc06
李文瀚	任职于	人工智能学院	doc04
人工智能学院	院长	王启明	doc02
李文瀚	研究方向	检索增强生成	doc04
AI 协会	指导教师	李文瀚	doc11

Q01 实际图中的子图 | 完整图 45 节点 / 40 三元组
沿入边找到教师，第二跳到学院，第三跳取得院长来源




图 2 完整知识图谱中的 Q01 关系子图

实际 Q01 只匹配“大模型通识课”：第 1 跳沿李文瀚主讲课的入边得到 doc06，第 2 跳李文瀚任职于人工智能学院得到 doc04，第 3 跳学院院长得到 doc02。最终文档顺序为 doc06、doc02、doc04、doc11、doc10，全证据命中。

默认保留严格子串匹配作为基线。另用空格、书名号归一及“云大→云山大学”别名做诊断：Q02 的 AI 协会由无匹配变为 AI 协会；归一后补回 doc11。去空格只能解决词面问题，不能自动处理重名教师或实体歧义。

2.3 WikiRAG（条目化知识库）

保留指南 9 个条目，平均正文长度为 74.4444 字符。正文嵌入相似度取 Top-3 条目，按相似度及来源列表顺序展开，再做文档去重。标题用于展示，不额外加入正文向量；条目预算 3 与文档预算 K 独立。

例如“人工智能学院”聚合 doc02 的院长和系、doc10 的重点实验室、doc15 的联合培养。条目减少跨文档阅读，但学院条目不含教师研究方向，校园条目省略校巴频率等细节；它还加入了原文没有的联合培养人数和教材名称。

预置条目原文与来源（保留参考数据，另做修正对照）

[人工智能学院] sources: doc02, doc10, doc15

人工智能学院成立于 2018 年，院长王启明教授，下设机器学习系、智能科学系、认知计算系。认知计算全国重点实验室依托本院建设。与新加坡南洋理工大学有本科联合培养项目（每年 15 人）。

[大模型通识课] sources: doc06

《大模型通识课》（AI2101）：3 学分 32 学时，春季学期开设，李文瀚主讲，面向全校本科生，无先修要求，教材《人工智能——深度学习大模型智能体》。

来源核查：doc15未写“每年15人”；doc06未写教材名称。

条目重写能聚合关系，也会遗漏原文细节或加入无依据内容。

图 3 参考条目原文 聚合来源与核查结果

主实验保留参考数据以便对照指南，修正版只移除无依据的信息并修正关系，不改原文或 gold。生成示例仅使用检索返回的原始文档，不把这些条目增写直接当作事实；这样能核查原文，但不能说明预置条目本身已经忠实。

3 对比实验设计

内置 15 题各类型 5 题；增加 5 题覆盖事实、多跳和全局，合计事实 6、多跳 7、全局 7。新增题在评测前固定证据，不根据排名修改 gold。三范式共享模型、问题文本和文档级 K=5；Graph 分别运行 Local 与 Global，避免把 scope 参数遗漏后得到相同路径。

Recall@K=命中的 gold 文档数÷gold 文档总数，逐题宏平均。MRR 先对返回文档去重，取前 K 篇中第一篇相关文档的排名 r，记 1/r；完全未命中记 0。条目、块和三元组都不是最终评价单位。

表 2 内置题示例与全部五道新增题

编号	类型	问题	evidence
Q01	多跳	《大模型通识课》授课教师所在学院的行政负责人是谁？	doc04, doc06, doc02
Q06	事实	云山大学的校训是什么？	doc01
Q11	全局	云山大学有哪些科研平台？分别依托谁建设？	doc10, doc02, doc03
Q16	事实	校内校巴共有几条线路，多久一班？	doc14
Q17	多跳	研究知识图谱的教师所授课程要求先修什么课程？	doc04, doc07, doc08
Q18	多跳	机器人战队指导教师所在学院下设哪些系？	doc11, doc04, doc02
Q19	全局	学校在图书资源和国际交流方面有哪些安排？	doc13, doc15
Q20	全局	两所学院分别开设哪些本科专业或下属系，负责人是谁？	doc02, doc03

新增证据依据：Q16 用 doc14 核查校巴线路和频率；Q17 以 doc04 教师研究方向→doc07 授课→doc08 先修规则关联；Q18 以 doc11 社团指导→doc04 任职→doc02 学院下设系关联；Q19 聚合 doc13 图书资源与 doc15 国际交流；Q20 比较 doc02/doc03 两学院的组织和负责人。完整 20 题见附录。

Q11 沿用指南 gold doc10、doc02、doc03，但科研平台及依托关系主要已写在 doc10。金标准覆盖不足不一定代表无法答题；后续同时展示原文支持、证据覆盖和答案是否完整。

4 实验结果与数据记录

4.1 检索质量 (Recall@5 与 MRR)

表 3 三范式 × 三类问题检索结果 (20 题)

范式	fact Recall	fact MRR	multi Recall	multi MRR	global Recall	global MRR
Vector	1.0000	1.0000	1.0000	1.0000	0.9048	1.0000
Graph Local	0.8333	0.8333	0.9524	0.9286	0.6429	0.4690
Graph Global	0.5000	0.3889	0.8333	0.7143	0.7857	0.6119
Wiki	1.0000	0.6944	0.9524	1.0000	0.6429	0.5476

表 3 统一为 20 题、文档 K=5。Vector 在事实与多跳题上 Recall 及 MRR 均为 1；全局 Recall 为 0.9048。Graph Global 的全局 Recall 为 0.7857，高于 Local 的 0.6429，但其事实 Recall 只有 0.5000。Wiki 事实 Recall 为 1，MRR 仅 0.6944，说明来源展开顺序让答案文档排得较晚。

表 3a 全题宏平均与全证据命中

方案	Recall@5	MRR	全证据命中
Vector	0.9667	1.0000	19/20
Graph Local	0.8083	0.7392	14/20
Graph Global	0.7167	0.5808	11/20
Wiki	0.8583	0.7500	16/20

本语料只有 15 篇短文；Vector 的高分与 BGE 中文匹配及小检索空间有关，不代表一般场景下向量检索必然最优。Graph Local 包含无实体匹配时的 Global 回退，其汇总不能被解释为所有题都依靠局部走边成功。

所有逐题返回文档、分数、路径、未命中证据保存于 eval20_local/global.json。未改成按问题类型自动选择 Graph 模式，也未依据 gold 挑选更好结果。

4.2 窗口敏感性（Top-K 扫描，任务四⑤）

表 4 不同 Top-K 下三类问题的 Recall（内置 15 题）

范式	类型	K=1	K=2	K=3	K=5
Vector	事实	1.0000	1.0000	1.0000	1.0000
Vector	多跳	0.4333	0.8000	0.8667	1.0000
Vector	全局	0.7667	0.7667	0.7667	0.8667
Graph Local	事实	1.0000	1.0000	1.0000	1.0000
Graph Local	多跳	0.3667	0.8000	0.9333	0.9333
Graph Local	全局	0.2000	0.4000	0.5000	0.7000
Graph Global	事实	0.4000	0.4000	0.6000	0.6000
Graph Global	多跳	0.1667	0.5000	0.7333	0.8333
Graph Global	全局	0.2667	0.5333	0.7000	0.9000
Wiki	事实	0.6000	0.8000	1.0000	1.0000
Wiki	多跳	0.4333	0.7000	0.8667	0.9333
Wiki	全局	0.3000	0.5000	0.6000	0.6000




图 4 真实嵌入的窗口扫描 每类型五题

K 扫描只用内置 15 题，每类型 5 题，与表 3 的 20 题分开。多跳 gold 有 2—3 篇文档，K=1 结构上不能拿满。例如 Vector 多跳 Recall 从 K=5 的 1.0000 降为 K=1 的 0.4333，降幅 0.5667，是该范式最大降幅。Wiki 全局在 K=3 和 5 均为 0.6000，说明仅扩大文档窗口不能补回未进入 Top-3 的条目。

4.3 忠实度评分（每范式抽 3 题）

表 5 忠实度 AI 初评 待人工确认

预选 Q01/Q06/Q11，覆盖三类题。Codex 只据各自 K=5 返回原文整理答案，无生成 API；完整答案、上下文和声明见 answer_review.json。human_score 为空，以下 AI 初评仍待人工核查。

范式	题号	AI 初评	关键句摘录	无依据断言 / 完整性
Vector	Q01	5 / 待确认	该学院院长是王启明教授[doc02]。因此行政负责人为王启明。	无；已回答
Vector	Q06	5 / 待确认	云山大学的校训是“格物致知”[doc01]。	无；已回答
Vector	Q11	5 / 待确认	岭南超算中心由云山大学与省科技厅共建，计算机学院参与运行管理[doc10]。	无；已回答
Graph Local	Q01	5 / 待确认	该学院院长是王启明教授[doc02]。因此行政负责人为王启明。	无；已回答
Graph Local	Q06	5 / 待确认	云山大学的校训是“格物致知”[doc01]。	无；已回答
Graph Local	Q11	5 / 待确认	本次检索上下文没有科研平台与建设依托关系的资料，无法据此列出完整答案。	无；部分回答或拒答
WikiRAG	Q01	5 / 待确认	本次检索未返回学院院长资料，无法确认行政负责人。	无；部分回答或拒答
WikiRAG	Q06	5 / 待确认	云山大学的校训是“格物致知”[doc01]。	无；已回答
WikiRAG	Q11	5 / 待确认	本次检索上下文没有科研平台与建设依托关系的资料，无法据此列出完整答案。	无；部分回答或拒答

量表：5=断言均受支持或谨慎拒答；4=个别边界含糊；3=部分无依据；2=多项无依据；1=主要内容无依据。九例未编造，初评均 5，不代表答题能力相同。

Graph/Wiki 的 Q11 缺平台资料而拒答，Wiki 的 Q01 缺院长资料而部分回答。无事实声明时式 8-8 分母为 0，比例不定义；拒答 5 分只表示未编造，不当作答题成功，不计算平均忠实度。人工须逐例确认或修改分数。

4.4 工程账对比

表 6 三范式构建与更新成本

范式	本次实际构建	新增一篇文档的变更	时间口径
Vector	分块、BGE 编码、向量矩阵	编码新增块并追加索引；原文修改时替换相关块	索引 0.1509 秒
Graph	载入 40 参考三元组、建图、检测社区，编码三元组及 3 摘要	校验三元组、合并实体；更新受影响社区与摘要，再编码	索引 0.1520 秒
Wiki	载入 9 参考条目与来源，编码正文	定位并重写相关条目、核查来源与冲突，再编码	索引 0.0889 秒

索引计时不含下载、7.59 秒模型加载、人工整理、关系抽取或改写。未做新增文档计时，更新栏只列所需步骤；预热与缓存也会影响秒数，不能据此判断生产成本。三种范式的增量维护区别见思考题 4。

4.5 MRR 手算验证（必做）

选题在查看排名前固定为 Q01、Q06、Q11，包含多跳题。0 表示 Top-5 未命中，倒数贡献为 0 而非 1/0；以下均按原始返回的文档级顺序计算。

表 7 MRR 手算与脚本核对

范式 / 题号	首次排名	1/rank 或 0	脚本核对
Vector / Q01	1	1.0000	一致
Vector / Q06	1	1.0000	一致
Vector / Q11	1	1.0000	一致
GraphRAG / Q01	1	1.0000	一致
GraphRAG / Q06	1	1.0000	一致
GraphRAG / Q11	0 未命中	0.0000	一致
WikiRAG / Q01	1	1.0000	一致
WikiRAG / Q06	1	1.0000	一致
WikiRAG / Q11	0 未命中	0.0000	一致

Vector: $(1+1+1)/3=1.000000$ ；Graph Local: $(1+1+0)/3=0.666667$ ；Wiki: $(1+1+0)/3=0.666667$ 。分别用 `--mrr_check 1,1,1` 与 `--mrr_check 1,1,0` 复核，与 `mrr_manual.json` 一致。手算这 3 题的均值不是表 3 或表 3a 全 20 题 MRR。

5 结果分析

5.1 分问题类型分析

在本次 20 题上，Vector 各类型 Recall 最高或并列最高，事实与多跳全部 gold 命中。多跳题的向量弱点主要在窗口收窄时显现：Q01 的课程和教师语义贴近问题，但院长的桥接文档 doc02 排第 4。Graph 能沿教师、学院、院长关系取得 doc02，但其效果依赖实体匹配和图连通性。

对全局题，Graph Global 比 Local 更适合聚合多个主题；Q11 Local 仅返回 doc01 中的大学基本信息边，Global 摘要却含院系和平台来源，使 Recall 从 0 恢复到 1。Wiki 依靠条目重写聚合资料，但 Top-3 条目筛选和来源列表先后会限制覆盖；扩大 K 未必能解决上游条目漏选。

Recall 描述证据是否齐全，MRR 只看首个相关文档来得早不早。Vector Q11 第 1 名 doc10 已支持完整平台事实，但 gold doc02/doc03 缺失，所以 $MRR=1$ 、 $Recall=1/3$ 。需要结合 gold 合理性、上下文内容与答案核查，不能只看单一指标。

5.1.1 选做 RRF 与来源修正对照

选做使用中文字符 bigram 词面余弦排名与稠密排名，按

$RRF=1/(60+r_dense)+1/(60+r_sparse)$ 融合。20 题事实 Recall 与 MRR 均保持 1.0000；全题 Recall 从 0.9667 降为 0.9583，MRR 从 1.0000 降为 0.9750，全证据命中由 19 降至 18 题。此负结果保留，不能写成混合检索必然提升。

单独修正三处来源问题后，Graph Local 全题 Recall/MRR 仍为 0.8083/0.7392；Wiki 变为 0.8417/0.7417，低于参考 0.8583/0.7500。忠实改写会改变嵌入排序，检索分数略降不能成为保留无依据内容的理由。主实验不替换成择优结果。

5.2 失败案例分析（每范式至少 2 例）

表 8 失败案例归因

范式 / 窗口	题号	真实返回 / 遗漏	原因
Vector K=5	Q11	doc10, doc01, doc04, doc11, doc05; 缺 doc02, doc03	平台原文 doc10 排第 1，但两学院背景 doc02/doc03 均未入 Top-5；保留指南 gold，语义排序未覆盖完整标注。
Vector K=3	Q01	doc06, doc04, doc05; 缺 doc02	桥接的学院院长 doc02 排第 4；K=3 时被计算机学院教师 doc05 挤出。K=5 恢复，并非 Top-5 失败。
GraphRAG K=5	Q02	doc02, doc04, doc06, doc07, doc08; 缺 doc11	AI 协会含空格，节点 AI 协会不含空格，未匹配实体而回退 Global；未返回 doc11。
GraphRAG K=5	Q11	doc01; 缺 doc02, doc03, doc10	只匹配云山大学，图中大学只连基本信息（均 doc01）；院系与平台子图未接入，局部走边只返回 doc01。Global 可补齐 gold。
WikiRAG K=5	Q01	doc06, doc04, doc11, doc05; 缺 doc02	Top-3 条目未选中人工智能学院，返回 doc06/doc04/doc11/doc05，缺少 doc02；条目数与文档 K 是两层预算。
WikiRAG K=5	Q13	doc02, doc10, doc15, doc11, doc13; 缺 doc04	学院教师条目未进 Top-3，学院条目并不含教师研究方向，doc04 遗漏。

Vector 的第二例明确来自 K=3：在 K=5 的 20 题中只有 Q11 未全证据命中。Graph Q02 是词面不匹配并触发回退；Q11 是关系链与学校节点未连通。Wiki 两例都是上游条目未选中，不能仅归咎于原文向量不好。

额外来源失败：Graph 三元组/摘要将计算机学院的“参与运行管理”改成“参与共建”；Wiki 增写“每年 15 人”及教材名称。前者改变责任关系，后两者原文无证据。来源审计保留对照并修正，而不是把预置数据当作天然无误的金标准。

6 AI 协作记录 Codex 使用情况

表 9 Codex 协作过程记录

序号	使用场景	实际提示词 / 操作	AI 输出与采纳
1	启动实验四	“实验四已更新。”	按指南与样板分析实验范围；延续前次目录结构
2	确定实现与 API	“你来就行，还需要 api 吗？”	采用指南允许的本地 BGE 与预置知识库，检索不需生成 API
3	代码实现与复核	Codex 实现、7 项测试、独立代码审查与结果回放	检查 scope、文档去重、JSON 形状、实体名称及 3 跳/6 前沿边界；接受通过核验的实现
4	本地运行与分析	CPU 正式 20 题、内置 15 题 K 扫描、Local/Global 与 RRF 对照	保留 Vector 更强与 RRF 无提升的实际结果，不以预期替代数据
5	报告与评分	按更新样板填报，保存上下文、答案及 AI 初评分	人工评分未确认；不记录尚未发生的亲手操作或人工评阅

本次由我指定实验资料并委托 Codex 实现、检查和整理。表 9 的引号内容是实际用户消息，其余为系统操作摘要；没有把生成的提示词草案写成我已经执行的原文，也不把此前实验二的个人操作声明移用到实验四。下一步需要我对九个答案与来源进行人工评分确认。

7 思考题作答

(1) 以 Q01 写出完整关系链，说明 Vector 与 Graph 获取多篇证据的机制。

完整关系链为：李文瀚—主讲→大模型通识课（doc06）；李文瀚—任职于→人工智能学院（doc04）；人工智能学院—院长→王启明（doc02）。查询从课程名开始，先沿入边找到教师，再到学院、院长。沿边获取的是候选证据，仍需核对关系方向和来源。

Vector 没有显式链约束，doc02 的院长资料与问题的课程名相似度较低。本次 doc02 排第 4，Top-5 实际取全，Top-3 才失败；不能为符合题面而声称 Vector 本次 Top-5 也漏了它。

Graph 的 3 跳展开取到 doc02，但若缺任职关系、实体匹配失败或前沿剪枝，仍可能断链。

(2) 设某 3 题首次命中排名分别为 2、1、4，MRR 是多少？另 3 题 Recall@5 均为 1.0 而 MRR 仅 0.4，两个指标分别在衡量什么？为什么必须一起看？

$MRR = (1/2 + 1/1 + 1/4) / 3 = 7/12 \approx 0.583333$ 。Recall@5=1 说明所需证据都在前 5 篇，MRR=0.4 说明第一篇相关证据平均来得不够早；例如首次排名 2、5、2， $MRR = (0.5 + 0.2 + 0.5) / 3 = 0.4$ 。

二者必须一起看：MRR 只关心第一次命中，漏掉链后段的必要文档也可能得 1；Recall 关心覆盖，却不反映答案文档排在第 1 还是第 5。手算与脚本应使用相同 K 和文档去重口径，未命中记 0。

(3) 全局问题（如 Q11「有哪些科研平台」）Vector RAG 会怎么失败？GraphRAG 的社区摘要为什么适合？WikiRAG 又靠什么机制解决？三者的本质差异是什么？

全局问题需要跨主题聚合。Vector 可能取到几个高度相关片段却遗漏较弱的院系背景；本次 Q11 命中 doc10，但 doc03 第 6、doc02 第 11，gold 覆盖只有 1/3。实际平台答案主要在 doc10，因此覆盖不足与答案是否可写是两层评价。

Graph Global 以预置主题摘要汇总来源，Q11 取得 doc02、doc03、doc10 等，全证据命中；Local 则因大学与平台子图未连接而失败。Wiki 通过主题条目把学院、实验室、国际项目重写在一起，理论上便于整体阅读，但本次 Q11 漏选平台相关条目而未命中 gold。三者分别按原文片段相似度、结构关系/社区摘要、主题化文本组织知识；摘要或条目还必须维护事实来源。

(4) 增量更新：学校新增一位教师。三种范式各自要改动什么（重算哪些块 / 图 / 条目）？从更新成本解释表 8-4 中三种范式的工程定位。

新增教师时，Vector 为新文档生成块向量并更新索引，原有文档不必全部重编码；若分块边界因编辑变化，替换受影响块。Graph 需抽取任职、研究与授课关系、确认是否同名同人、添加带来源的边；社区结构改变时需重新检测或更新受影响社区摘要。

Wiki 需把教师信息并入学院教师或课程等主题，检查旧事实冲突并保留新来源，再更新这些条目向量。本代码尚未实现持久化增量维护，当前只是重新构建小索引；表 6 描述增量工作的工程定位，不宣称已实现生产级更新接口。

(5) 忠实度人工评分的主观性如何缓解？RAGAS 用 LLM 自动评忠实度的思路是什么（式 8-8），这种「用 LLM 评 LLM」又引入了什么新偏差？

人工评分可用统一量表、隐藏范式名称、先拆原子事实、逐条标注来源，再由两人独立评分并讨论分歧。必须同时记录答案完整性，防止拒答总获高忠实度却没有解决问题。对于没有事实声明的输出，支持比例分母为 0，应另行处理。

按教材式 8-8，自动评忠实度先把答案拆成事实声明，再检查每条是否能由检索上下文推出，以支持声明数÷总声明数得到比例。RAGAS 采用此类 LLM 辅助检查思路。[4] 评分模型也可能误拆声明、漏查否定、受表达风格影响或偏好自己的答案。固定评审模型和提示、抽样人工复核及报告分歧能减轻偏差；本次没有运行 RAGAS，表 5 只是 Codex 初评。

(6) GraphRAG 的抽取提示词与代码审查中有哪些关键检查？

本次保留两版抽取提示词草案，但没有进行现场 LLM 抽取或多轮 API 试验。第一版仅要求头实体、关系、尾实体和 JSON；第二版补充“只抽取原文支持、保留全称、不把运行管理写成共建、不补人数年份教材”。这一约束来自对预置来源错误的核查；不能据草案数量声称成功迭代了两轮抽取。

代码需检查：JSON 只用 `json.loads`，禁止 `eval`，数组必须由三个非空字符串组成；来源号存在并可追溯。实体归一需保留原名、处理空格和别名，避免把不同人物合并。多跳展开需要限制深度及前沿，去重节点与边并记录回退；`global` 参数必须实际传入检索函数。格式合格也不代表三元组语义正确，最终仍要对照原文。

附录 全部问题与复核记录

表 A1 全部 20 题与固定 gold

编号	类型	问题	evidence
Q01	多跳	《大模型通识课》授课教师所在学院的行政负责人是谁？	doc04, doc06, doc02
Q02	多跳	AI 协会的指导教师主讲课程的课程代码是什么？	doc11, doc04, doc06
Q03	多跳	认知计算全国重点实验室依托的学院成立于哪一年？	doc10, doc02
Q04	多跳	《知识图谱导论》授课教师的研究方向是什么？	doc07, doc04
Q05	多跳	机器人战队的指导教师的研究方向是什么？	doc11, doc04
Q06	事实	云山大学的校训是什么？	doc01
Q07	事实	国家奖学金的金额是多少？	doc09
Q08	事实	图书馆每天几点到几点开放？	doc13
Q09	事实	人工智能学院成立于哪一年？	doc02
Q10	事实	春季学期什么时候开学？	doc12
Q11	全局	云山大学有哪些科研平台？分别依托谁建设？	doc10, doc02, doc03
Q12	全局	学校的学生奖励体系包含哪些项目？	doc09
Q13	全局	人工智能学院有哪些教师？各自做什么研究方向？	doc04
Q14	全局	本科生选课有哪些限制和先修要求？	doc08
Q15	全局	对想深入学习大模型的学生，学校提供哪些课程和课外活动？	doc06, doc11
Q16	事实	校内校巴共有几条线路，多久一班？	doc14
Q17	多跳	研究知识图谱的教师所授课程要求先修什么课程？	doc04, doc07, doc08
Q18	多跳	机器人战队指导教师所在学院下设哪些系？	doc11, doc04, doc02
Q19	全局	学校在图书资源和国际交流方面有哪些安排？	doc13, doc15
Q20	全局	两所学院分别开设哪些本科专业或下属系，负责人是谁？	doc02, doc03

独立复核：7 项逻辑测试通过；19 组实验共 730 条逐题结果、180 条汇总指标与完整检索对象离线回放一致；4 条实体归一诊断与 3 组 MRR 核对一致。指定 BGE 本地权重重新编码 92 个文本，最大差约 1.45×10^{-7} ，确认正式结果来自真实模型。

复现入口：python run_experiments.py --revision

7999e1d3359715c523056ef9478215996d62a620 --output results_reproduced; python -m unittest test_hw4_rag -v; python analyze_results.py --verify-only。结果 manifest、环境、原文、逐题记录和向量均保留。模型权重、缓存、虚拟环境不进入 Git。

本地依照实验一至三的文件结构：提交材料保存正式报告，lab04_rag 保存代码、原始结果与报告副本，tools 保存构建与排版核验。Git 规范目录为 labs_repo/lab04。实验四未连接 HPC、未启动远程作业。待完成项为 9 例人工忠实度评分；当前明确保留 AI 初评状态。

仓库：<https://github.com/s-max-oss/llm-course-labs/tree/main/lab04>

参考资料

[1] 课程资料：作业四实验指南、更新后的实验报告样板；Lesson08 第八章，特别是式 8-6、8-8 至 8-10。

[2] BAAI. bge-small-zh-v1.5 官方模型卡。<https://huggingface.co/BAAI/bge-small-zh-v1.5>（512 维与查询指令）

[3] Sentence Transformers 模型 API 文档；NetworkX greedy_modularity_communities 官方文档。
https://sbert.net/docs/package_reference/sentence_transformer/model.html ;
https://networkx.org/documentation/stable/reference/algorithms/generated/networkx.algorithms.community.modularity_max.greedy_modularity_communities.html

[4] Es S, et al. RAGAS Automated Evaluation of Retrieval Augmented Generation. EACL 2024 Demonstrations. <https://aclanthology.org/2024.eacl-demo.16/>