实验作业五 SmolVLM 256M 的 QLoRA 微调与 DPO 偏好对齐

姓名：孙驰　　学号：2024311281　　班级：计算机 10 班

完成日期：2026 年 10 月 14 日

一 实验概述

本实验按指导书完成几何图形问答的基线、QLoRA 监督微调、DPO 偏好对齐以及 β 敏感性对照。正式训练使用 HPC 的 NVIDIA A30，SFT 为 60 步、四组 DPO 各 40 步，原 12 组偏好对扩展为 17 组；没有沿用模板中的 CPU 演示结果。

逐题语义复核后三阶段正确率为 7/15、6/15、6/15。SFT 改善数数格式，却损失了属性答题能力；DPO 降低了偏好对损失，但未提高任务语义正确率，且 β=0.1 时部分完整否定变为口语“没”。本实验重点是分清答案正确、附加事实忠实与表达完整这三个维度。

1.1 运行环境

表 1 正式实验环境

项目	实际配置	说明
算力	HPC gpu4；NVIDIA A30 24GB	单 GPU、4 个 CPU 核；Slurm 14595
运行软件	Python 3.10.20；torch 2.6.0+cu124	Linux 5.4.0-100；CUDA 运行库 12.4
模型依赖	transformers 4.57.6；peft 0.17.1	accelerate 1.10.1；bitsandbytes 0.48.1
模型	HuggingFaceTB/SmolVLM-256M-Instruct	revision 7e3e67ed…；离线复用，完整版本与哈希随附
量化/输入	NF4、双重量化、BF16 计算	原图 256×256，统一 512 单视图；不做多裁剪
运行安排	60+4×40=220 个优化步	仅计算节点训练；准备/烟测/正式作业均已结束

1.2 各环节实测耗时

表 2 正式命令墙钟耗时

环节	秒	计时范围
BF16 基线 / NF4 基线	13.49 / 18.90	各含加载与 15+5 题推理
SFT 60 步	39.85	含加载、训练、保存与 20 题评测
DPO 12 对 / 17 对 β=.1	43.37 / 51.74	各 40 步，含参考缓存和前后全池诊断
17 对 β=.05 / .5	84.35 / 53.52	同一 SFT 起点、同种子与相同步数
正式 Slurm 作业	312（5 分 12 秒）	00:02:53 完成，退出码 0:0；队列为空

上述是一次运行的墙钟时间，含 I/O、模型加载与评测，不能当作单步速度或精确的硬件效率比较。SFT 训练及预处理 24.01 秒；主 DPO 对应 34.36 秒，含参考缓存与全池前后诊断。实测峰值 CUDA 分配约 0.665GiB 与 2.620GiB；这不是整卡总显存占用。

二 QLoRA 与 SFT 实现

2.1 量化基座与语言适配器

视觉编码器把图像变为视觉 token，与问题文本一同进入语言模型。每个 512 视图编码为 64 个视觉 token。[2] NF4 负责压缩被冻结的线性权重，双重量化压缩量化常数；训练只更新语言注意力 q/k/v/o 投影的 LoRA，使用分页 AdamW32bit。其余权重均冻结，视觉塔没有 LoRA 参数。[3–4]

$$\Delta W = (\alpha/r)BA \quad r = 8,\ \alpha = 16$$

表 3 逻辑参数量与训练范围

总参数	可训练参数	占比	范围
257,406,528	921,600	0.358033%	30 层语言注意力的 q/k/v/o；240 个适配器张量

```
Actual print_trainable_parameters output / sft.log
trainable params: 921,600
all params: 257,406,528 || trainable%: 0.3580
```

图 1 真实训练日志中的参数统计输出 排版摘录

总量按 PEFT 逻辑参数口径统计，已补偿 Params4bit 的打包存储，不把 4-bit 存储元素数当作原始参数数。模板示例的 1,363,968 与 0.529%不适用于当前语言层限定配置；本次实际为 921,600 与 0.358%。低秩矩阵虽小，仍能改变每层注意力的特征变换及最终 token 分布；参数少不保证每类任务都提升。

2.2 SFT 的标签掩码

学习率 1×10^{-4}，batch=1，dropout=0.05，随机种子 42，每轮打乱 15 条正例并循环到准确的 60 个优化步；梯度范数裁剪为 1。避免参考代码只运行两轮而最多训练 30 步的问题，也保证非整轮步数仍保存最终适配器。

问题经带图像的 chat template 处理，答案单独分词后追加到同一个 prompt token 前缀，最后追加 EOS。labels 的整个 prompt（含图像和助手前缀）设为−100，仅答案和 EOS 受监督；attention_mask 同步增长。这样避免把拼接后的 BPE 边界误当作原 prompt 长度。15 条 mask_audit 均已保存。

$$\log \pi(y|x) \;=\; \Sigma_t \in \text{答案及 EOS} \log p(y_t \mid x,\ y_1, \ldots, y_{t-1})$$

计算序列概率时，logits 去掉最后一位、labels 去掉第一位完成因果对齐；答案位置的 log-softmax 求和，不能取长度平均。以上表达中的条件表示此前答案 token。SFT 使用模型的答案 token 平均交叉熵；DPO 使用整段答案对数概率之和，两种口径分开实现。

三 对比实验设计

保留指南随机种子 42 生成的 15 张原图、15 道中文问题及标准答案：count/attr/exist 各 5 题。主对照用同一 NF4 基座、同一 512 单视图处理、同一贪心解码（最多 32 个新 token）；BF16 无量化基线单独报告。四组 DPO 均重新载入同一份 SFT 适配器，不串行叠加或嵌套 PeftModel。

表 4 实验组及控制变量

组别	数据 / 步数	优化与用途
BF16 基线	无训练；20 题推理	补充观察量化前后的输出差异
NF4 基线	无训练；20 题推理	主对照；冻结权重和非量化层精度与 SFT 一致
SFT	15 条正例；60 步	r=8，α=16，lr=1e-4
DPO 原 12 对	12 对；40 步，β=.1	同一 SFT 起点，lr=5e-5
DPO 扩展 17 对	12+5 对；各 40 步	β=.05/.1/.5，其他设置固定；.1 为主 DPO

重要边界：15 题本身用于 SFT，又用于评测，属于训练集复测；5 道新增题也进入扩展 DPO，不能当作独立测试集。实验只观察同一小样本的行为变化，不证明泛化。图像存在原指南随机重叠，如 img10 的蓝圆、img14 的方形；保留原图保证对照，不改图后沿用旧 gold。

原规则匹配与语义答案复核并存：No 可表示否定，单字“没”在有没有问句下同样表示否定；针对绿色对象明确回答 green square 也算属性正确，附加圆形/位置幻觉另评。共 140 份实际输出中有 10 条因此调整，原 JSON 和自动分数均保留。复核由 Codex 及独立 Codex 审查完成；不是学生盲审。

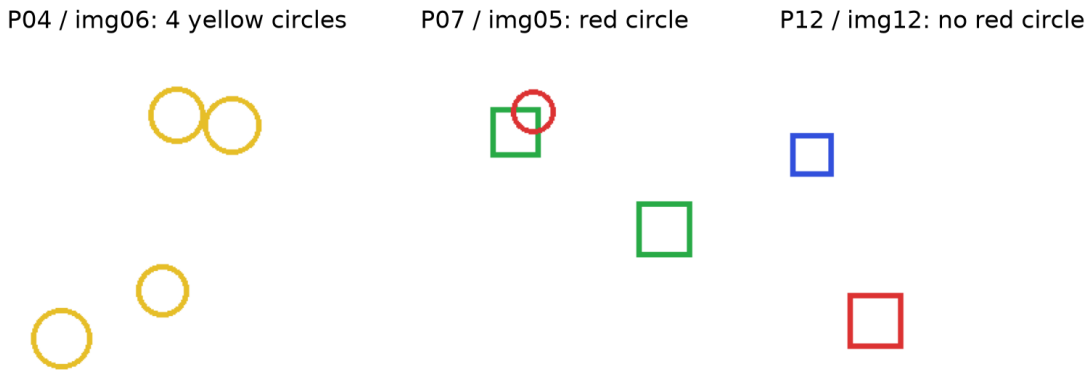


图 2 三道抽样题的原图 其余 12 张随数据保存

四 结果与数据记录

4.1 三阶段任务正确率

表 5 同题语义答案正确率 分母每类 5 题

阶段	count	attr	exist	总计 /15	正确率
基线 NF4	1/5	4/5	2/5	7/15	46.7%
SFT 60 步	3/5	0/5	3/5	6/15	40.0%
SFT+DPO 17 对	3/5	0/5	3/5	6/15	40.0%

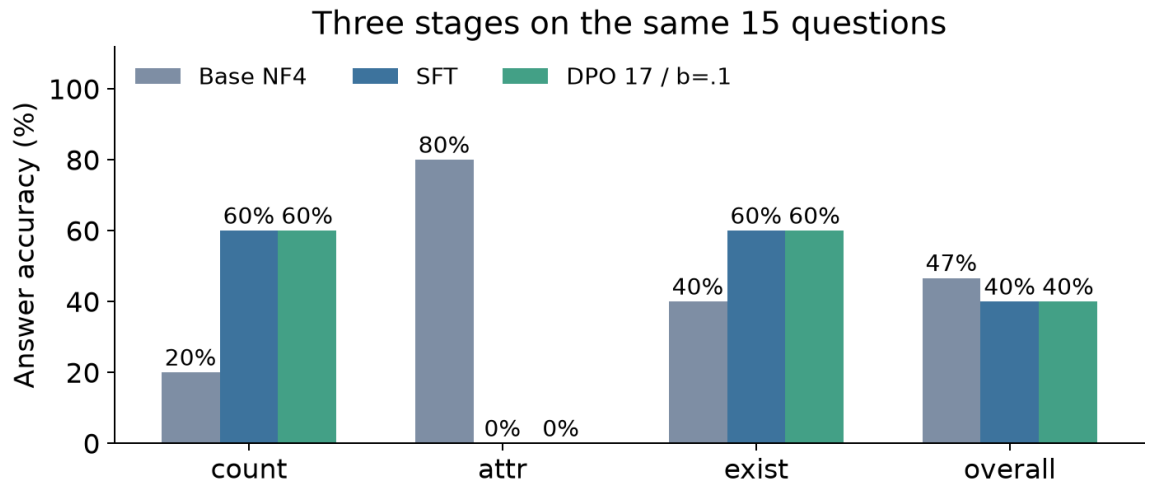


图 3 三阶段语义正确率 同一训练题上的复测

SFT 数数由 1/5 提高到 3/5，输出从英文描述转为中文数字；但属性由 4/5 降为 0/5，模型输出“三角”“形状”“主题”等错误或无效词。存在性由 2/5 到 3/5，是全部回答否定后恰好命中三个负例，并未学会区分两道正例。DPO 扩展 17 对后语义正确数仍为 6/15，未提高这一能力。

表 6 原规则得分与逐题语义复核并列

阶段	原规则 /15	语义复核 /15	差异来源
基线 NF4	6/15	7/15	绿色对象绑定正确但附加描述不忠实
SFT 60 步	6/15	6/15	无差异
SFT+DPO 17 对	4/15	6/15	P12/P14 的没是口语否定；完整性另评

因此，自动规则的 40%→40%→26.7%不能直接解释为 DPO 事实能力下降。语义表反映所问答案，忠实度表审查额外断言和表达质量；原规则表用于复现脚本口径，不用于挑选有利结果。BF16 基线另为 0/5、3/5、3/5，共 6/15；不能把 BF16 与 NF4 的差异都归于训练。

4.2 全部 15 题结果

表 7 三阶段逐题结果 语义复核后 √为正确

题号 / 类型	问题	gold	基线	SFT	DPO
P01 / 数数	图中有几个红色圆形?	2	×	√	√
P02 / 数数	图中有几个绿色圆形?	3	×	×	×
P03 / 数数	图中有几个黄色方形?	2	×	√	√
P04 / 数数	图中有几个黄色圆形?	4	×	×	×
P05 / 数数	图中有几个蓝色圆形?	3	√	√	√
P06 / 属性	图中蓝色的图形是什么形状?	方形	√	×	×
P07 / 属性	图中红色的图形是什么形状?	圆形	×	×	×
P08 / 属性	图中绿色的图形是什么形状?	方形	√	×	×
P09 / 属性	图中黄色的图形是什么形状?	圆形	√	×	×
P10 / 属性	图中蓝色的图形是什么形状?	方形	√	×	×
P11 / 存在	图里有没有黄色方形?	有	×	×	×
P12 / 存在	图里有没有红色圆形?	没有	×	√	√
P13 / 存在	图里有没有绿色圆形?	有	√	×	×
P14 / 存在	图里有没有绿色方形?	没有	√	√	√
P15 / 存在	图里有没有蓝色图形?	没有	×	√	√

逐题完整原文和自动/语义两种判分保存于 results 与 analysis/summary.json；表 7 不省略失败题。图中有绿圆时 P13 仍答否定，count 的 P02/P04 仍数错，attr 五题均未通过训练恢复。

4.3 抽样原文与本人确认评分

固定 P04/P07/P12 三题，分别覆盖 count/attr/exist，各取三阶段输出，共 3 道题×3 阶段=9 份回答。本人参考 AI 建议及图像依据确认以下分数，未进行独立盲审。量表同时看事实忠实和表达质量：5 忠实且完整；3 部分正确或表达不足；2 主要答案错误/残缺；1 场景编造。任务语义与表达评分可不同。

表 8 九份完整回答与确认评分

阶段 / 题号	输出原文	分数	依据
基线 NF4 P04	There are two circles in the image.	2	计数 2 而非 4，主要事实错误
基线 NF4 P07	The image is a screenshot of a graphical user interface.	1	将几何图描述为 GUI 截图，场景幻觉
基线 NF4 P12	Yes, there are blue squares.	3	蓝方事实正确，但 Yes 错误回答红圆存在性
SFT 60 步 P04	2 个。	2	计数 2 而非 4，主要事实错误
SFT 60 步 P07	三角。	2	将红圆答为三角，形状错误
SFT 60 步 P12	没有。	5	完整否定与图中事实一致
SFT+DPO 17 对 P04	2。	2	计数 2 而非 4，主要事实错误
SFT+DPO 17 对 P07	三。	2	三字没有给出所问形状，答复质量低
SFT+DPO 17 对 P12	没。	3	口语没是正确否定；学生认可按表达完整性扣分，不认定为事实方向错误

P12 的“没”可以正确表达否定，3 分是本人认可的表达完整性扣分，不是把它判为事实方向错误。按以上评分推导，SFT 对基线胜 2/3、平 1/3；DPO 对 SFT 胜 0/3、平 2/3、负 1/3。该相对偏好只覆盖 3 题，且不是另一次匿名盲选，不能推广为总体偏好胜率。

五 结果分析

第一，低秩适配器有效改变了输出分布，但改变不等于改善。SFT 前 10 步平均 loss 为 2.8161，后 10 步为 0.5660；数数的简洁格式明显形成，属性却从可匹配的英文词退化为中文无效词。本实验无法单凭 15 个重复训练样本区分语言适配、遗忘、视觉绑定和训练超参各自的影响。官方模型卡以英语为主要语言，中文问句与极小训练集是合理的影响因素，但不是已被消融证实的原因。[2]

第二，DPO 优化的是相对于参考模型的 chosen/rejected 概率差，不直接优化贪心解码正确率。17 对 β=.1 的全池 loss 由 0.5113 降至 0.3398，平均 margin 由 0.5432 增至 1.6910；chosen 平均序列 logp 却从−8.1749 降到−9.0331，rejected 从−29.3112 降到−41.6473，后者降得更多足以改善目标。这说明损失下降不保证正确答案绝对概率上升，也不保证输出更完整。

第三，偏好数据扩充有局部作用。原 12 对 DPO 语义正确 4/15，扩展 17 对为 6/15；新增题由 2/5 到 4/5。但两者重复训练样本的覆盖不同，且只有单种子，不能把 2 题差值当作普遍收益；A03 的绿色形状仍答“的”，新增偏好并未消除形状失败。

第四，β 扫描没有改善语义正确率：三组均 6/15。β=.5 更多保留完整“没有”，而.05/.1 更多使用“没”，导致原规则得分和表达完整性不同。β 是 DPO 理论目标中的 KL 约束系数，不能机械地说越大就越偏离参考；有限步优化还受梯度幅度和饱和影响。本次数据不支持“β 大必然更差”的结论。[5]

六 失败案例与环境记录

6.1 真实失败与错误归类

表 9 失败案例及证据

阶段 / 题号	现象	对照依据与判断
基线 NF4 / P02	There are two colored circles in the image.	图有 3 个绿圆，却数成 2；真实计数错误。
基线 NF4 / P04	There are two circles in the image.	图有 4 个黄圆，却说 2；另一计数错误。
基线 NF4 / P11	The image is a screenshot of a webpage.	只有黄色方形，答网页截图；存在题未回答且编造场景。

阶段 / 题号	现象	对照依据与判断
基线 NF4 / P12	Yes, there are blue squares.	没有红圆，答 Yes 并改谈蓝方；蓝方属实不能使结论正确。
SFT 60 步 / P07	三角。	红色是圆，答三角；SFT 的形状错误。
SFT+DPO 17 对 / P12	没。	没是正确口语否定，表达不完整；不把格式退化冒称新增幻觉。

以上逐例原文保留，没有用预期现象替代真实失败。另两例展示“答案匹配对、附加说法有问题”：BF16 P08 明确 green square，却扩写成不同文化中的纯洁象征，超出图像支持；NF4 P08 明确 green square，却称整体为圆形、方形在中心，实际绿方位于上方偏左。两例均为属性答案可得分、忠实度应另扣，不能只查 square 词就宣布完全正确。

6.2 实现与环境修正

表 10 排查记录

问题	处理与核验证据
SSH 用纯学号被拒绝	按平台文档改为 u+学号，免密连接成功；未改服务器认证设置。
模板预填 CPU 与旧结果	全部替换为 A30 实测；原模板保持原文件哈希。
参考手算函数符号相反	改为 softplus(−margin)，四组手算与真实 CLI 一致。
参考循环上限与保存位置	按优化步循环，60/40 步均实际完成；默认目录与 SFT 接续已测试。
有/没有子串与复合数词	区分正负；不把十二误当二；附加不相关 not 及矛盾分句设回归例。
规则分数混淆语义	保存 10 条口语否定/属性绑定修正，原输出和原分数不改。
参考计算与适配器	disable_adapter+no_grad；固定基座标量缓存；同 SFT 重启，无嵌套。

准备作业 14588 与 GPU 烟测 14593 也已 COMPLETED 且 0:0；正式 14595 在 2026-10-14 00:02:53 结束，随后队列为空。作业结束自动释放共享 GPU 和 CPU，没有留下交互式申请或独占实例。

七 AI 协作记录

本次协作中,我把自己定位为提出者、审阅者和验收者:实验范围、评价口径和提交标准由我确定,具体实现、运行与检查由 Codex 执行。我坚持一个原则——凡是写进报告的结论,我必须先读懂对应代码、说清对应公式,并能在保存的文件里找到依据。以下按“阅读—提问—修改—验收”记录我的实际参与,并如实区分哪些工作由 AI 完成。

逐段阅读时,我重点弄清五处最容易出错的实现:答案为何单独分词(避免 BPE 边界导致 prompt 长度错位并污染掩码)、logits 与 labels 为何错开一位(自回归预测下一个 token)、参考模型为何取关闭适配器的基座(与以 SFT 权重作参考的做法区分开)、序列概率为何求和而非求平均(DPO 需要整段答案的 log 概率之和)、规则评分为何必须配合语义复核(“有/没有”与“十二/二”等子串陷阱)。对不确定的地方我直接追问,并要求给出代码位置与保存证据;例如“为什么参考路径必须 eval+no_grad 且只缓存标量”,解释后我对照 preference_diagnostic 与逐步训练记录确认。

修改与优化由我在审阅中推动:复算手算题时,我发现参考自检函数返回的 loss 与 softplus(−margin) 公式符号相反,四组手算与 CLI 结果对不上,定位后要求修正并重新核对;测试默认 infer→sft→dpo 流程时,发现各模式默认输出目录都指向 results/baseline,导致再次运行基线时拒绝覆盖、默认 dpo 找不到 SFT 适配器,要求按模式区分默认目录并补 CLI 行为测试。两处修正均复核通过后才写入报告。

评价方面,我逐份确认了九份抽样评分:参考 AI 建议与图像依据判断,接受或修正,其中 P12 的“没”按表达完整性扣 3 分、明确不判为事实方向错误;我还要求把语义正确率、附加事实忠实度和表达完整性分表记录,避免用单一规则分数下结论。评分方式如实写为“本人确认 AI 建议”,未虚构独立盲审;代码与数据另经独立 Codex 核验。

表 11 任务组织与协作分工

环节	我的参与	Codex 辅助与验证
任务与材料	更新课件和实验五,明确按课程要求完成并沿用归档方式;依据平台文档确认 HPC 用 u+学号登录,要求查文档解决而不是改服务器认证。	核对指南与模板,替换样板预填结果,补全必做和选做对照。

环节	我的参与	Codex 辅助与验证
代码阅读	逐段阅读 hw5_dpo.py 核心实现,标出五处最易写错的代码:输入构建 encode_answer、可训练范围 load_model、概率口径 sequence_logprob、DPO 目标 dpo_loss/scalar_dpo、评分 legacy_judge/judge。	按阶段拆分代码并给出阅读入口;对阅读中的疑问逐条解释并指出对应代码位置。
提问与追问	就五处不理解的细节追问,例如:答案为何单独分词而不拼接后整体编码、logits 与 labels 为何错开一位、参考模型为何用关闭适配器的基座而非 SFT 权重、序列概率为何求和而非平均、规则评分为何要配合语义复核。	逐条解释并给出依据:回答单独分词避免 BPE 边界错位、mask_audit 15 条逐条保存、参考路径 eval+no_grad 且缓存标量。
修改优化	复算手算题时发现参考自检函数返回的 loss 与 softplus(−margin) 公式符号相反,四组手算与 CLI 对不上,定位后要求修正并复算;测试默认 infer→sft→dpo 流程时发现各模式默认输出目录都指向 results/baseline,要求按模式区分默认目录并补 CLI 行为测试。	完成两处修正:四组手算与真实 CLI 一致;默认目录按模式选择,CLI 行为测试通过。
实现与质量	委托完成实验,要求以代码、数据、报告形成可提交成果,并明确负面结果与失败样本必须保留、不得用预期现象替代真实失败。	实现掩码、QLoRA 与 DPO,修正脚手架错误,11 项行为测试及独立代码/数据审查。
结果与评分	参考九例建议及图像依据,逐份确认评分与理由;把 P12 的“没”按表达完整性扣 3 分并明确不判事实方向错误;要求语义正确、事实忠实与表达完整三个维度分开记录。	分开记录语义正确率、忠实度与表达质量,保留原输出和全部失败结果。

环节	我的参与	Codex 辅助与验证
报告与提交	逐节审阅提交稿,要求区分末步 loss 与全偏好池前后诊断、区分训练集复测与独立测试,手算四组与 CLI 对照写入正文;确认表 5/表 7/表 8 数字与 results、analysis/summary.json 一致。	整理图表、手算、复核记录与复现命令,完成排版归档和仓库同步。

提交前我逐节审阅了报告,核对三阶段正确率、逐题结果与九份评分同 results 及 analysis/summary.json 一致;评分采用本人确认 AI 建议的方式,未开展独立盲审。代码和数据另经独立 Codex 核验,两类复核记录随结果保存。

八 思考题

题 1 SFT 与诚实否定

P12 图中没有红圆。SFT 通过“没有”的正例可提高正确否定概率，softmax 交叉熵也会间接压低其他 token，不能绝对地说 SFT 从不惩罚错误答案；其不足在于没有针对具体错误回答提供相对偏好。本次 SFT 对所有 exist 题均答没有，命中 3 个负例却错失 P11/P13 两个正例，表明学到否定偏置不能等同诚实识别。DPO 的 rejected“有，左上角有红圆”可直接针对该错误，但本次并未学会区分正负场景。

题 2 margin 与损失手算

题设 chosen 差为 1.5−1.0=0.5，rejected 差为 0.2−0.6=−0.4；margin=0.1×[0.5−(−0.4)]=0.09，loss=ln(1+exp(−0.09))=0.649159339。margin<0 表示 chosen 相对 rejected 的提升小于参考模型，不必等同 policy 的 chosen 绝对概率小于 rejected。四组 CLI 复核见第九节。

题 3 DPO 的隐式奖励

$$r(x, y) = \beta \log[\pi\theta(y|x)/\pi ref(y|x)] + \beta \log Z(x)$$

带 KL 约束的最优策略与奖励之间可用上述关系互换。将其代入 Bradley–Terry 的 σ(rw−rl)，同一问题的 log Z(x)相消，偏好概率就成为策略与参考 log 比值差的 sigmoid。直接最大化偏好对似然即可训练 policy，不必先拟合单独奖励网络，也不需要训练时采样再跑 PPO；参考策略仍然不可少。[5]

题 4 量化与秩的参数估算

4-bit 存储节省的是冻结基座内存；若全参更新，还需处理离散量化、保留高精度梯度及优化器状态，低显存优势会大幅减少。LoRA 的 A/B 在可微路径中训练，基座仅按需反量化参与计算。[3–4] 本次 r=8 为 921,600 参数；固定投影维度，r=16 约为 1,843,200。计入适配器后的总量为 258,328,128，占约 0.713513%，约为当前占比的 1.993 倍，而非所有模型参数翻倍。

题 5 自动偏好对的好处与风险

模型生成多种候选再按规则打分，可以减少编写负例的时间，并覆盖模型真实会犯的错误；但规则漏洞、同模型偏差、颜色数数错误和长度偏好会被一起放大。本次 not 与没有子串、口语没就能造成指标偏差；若自动规则给这些回答错误奖励，会把评分器漏洞当作任务目标。应抽查图像事实、保留长短答案的平衡、设置独立保留题，检查 chosen 与 rejected 绝对 logp，并避免只凭 DPO loss 选模型。

题 6 协作中关键代码的验证

最容易悄悄写反的是 margin 中 chosen 和 rejected 的顺序；同样隐蔽的是漏掉因果位移或把整段 prompt 计入损失。验证包括：手算的正、零、负及极端 margin；梯度方向测试要求下降时 chosen logp 升、rejected 降且参考无梯度；合成 logits 测试 prompt 和最后无目标位置梯度为 0；边界分词/EOS 掩码测试；真实参考概率在训练前后逐项相同。关闭适配器必须位于 no_grad 内，不能把 SFT 和 DPO 适配器层层包装。独立检查与测试由 Codex 执行，本人参考结果组织实验记录。

九 DPO 偏好对齐与选做对照

9.1 新增五组偏好对

保留指南 12 组 chosen/rejected，覆盖数错、形状幻觉、硬答有；扩展如下 5 组，chosen 从图像规格真值核对。A05 故意让 rejected 的数量也正确，只在冗长补充中加入虚构事实，避免所有负例都只以错误数字或长度区分。

表 12 新增偏好对及失败模式

编号 / 图	问题	chosen	rejected / 失败模式
A01 / img04	图中有几个红色方形?	3 个。	4 个。 计数加一
A02 / img07	图中有几个蓝色方形?	2 个。	1 个。 颜色对象混淆导致计数错误
A03 / img13	图中绿色的图形是什么形状?	圆形。	方形。 形状幻觉
A04 / img14	图里有没有红色圆形?	没有。	有，一个红色圆形。 把红色方形误认成圆形，硬答有
A05 / img15	图中有几个绿色圆形?	2 个。	2 个。旁边还有一个红色方形，图中物体排列得非常整齐。 数量正确但冗长补充虚构物体及排列

9.2 DPO 实现与参考模型

$$\Delta w = \log \pi\theta(yw|x) - \log \pi ref(yw|x)$$
$$\Delta l = \log \pi\theta(yl|x) - \log \pi ref(yl|x)$$
$$\text{margin} = \beta(\Delta w - \Delta l)，\ L = -\ln \sigma(\text{margin})$$

按指南，参考取关闭 LoRA 后的同一 NF4 基座，而通常 DPO 也常用冻结 SFT 模型作为参考；两者不可混称。本次在 SFT 适配器上继续优化，lr=5×10⁻⁵、batch=1、40 步。参考路径 eval+no_grad，policy 也关闭 dropout 但保留梯度，避免参考/策略随机噪声污染 log 比；SFT 阶段仍用训练 dropout。参考标量只计算一次并缓存，不保留参考模型梯度。

9.3 手算与命令核对

表 13 四组 DPO 手算和实际 CLI 复核

组别	pw,rw,pl,rl,β	margin	loss
指南给定例	1.2,0.8,0.9,0.6,0.1	0.0100	0.688159681
思考题 2	1.5,1.0,0.2,0.6,0.1	0.0900	0.649159339
自选 A	-4,-3,-2,-3,0.1	-0.2000	0.798138869
自选 B	-2,-3,-4,-3,0.5	1.0000	0.313261688

指南例：(1.2−0.8)−(0.9−0.6)=0.1，乘 β 得到 0.01；$\ln(1+e^{-0.01})=0.688159681$。指南的 ≈0.693 是接近 ln2 的粗略值，精算与当前函数一致；参考代码原检查函数返回负 loss 的符号问题已修正。题设正数按给定代数输入复核，不能当作真实的正序列 log 概率；训练中的 log 概率均非正。

自选 A：[−4−(−3)]−[−2−(−3)]=−2，乘 0.1 得−0.2，loss=0.798138869。自选 B：[−2−(−3)]−[−4−(−3)]=2，乘 0.5 得 1，loss=0.313261688。四组完整命令及输出保存在 analysis/dpo_hand_checks.json；负数串命令使用--dpo_check=形式。

9.4 训练曲线及完整偏好池诊断

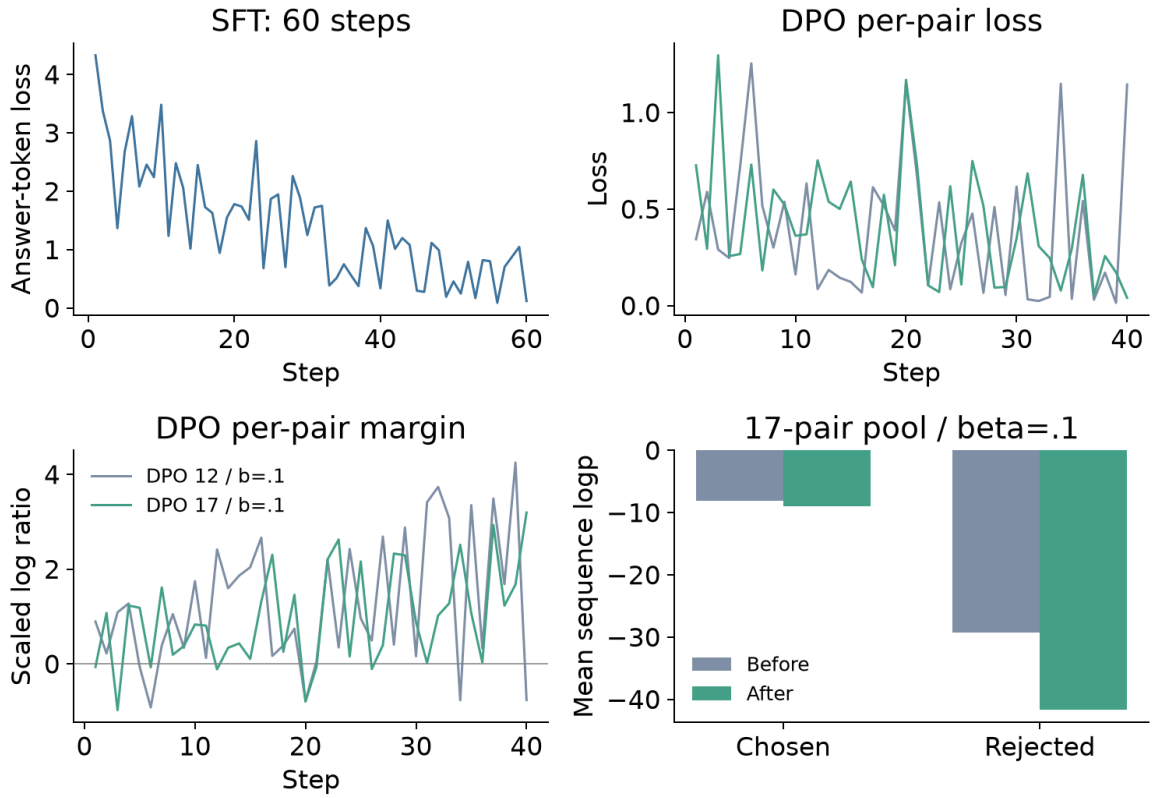


图 4 SFT loss 与 DPO loss margin 的真实逐步记录

逐步曲线是不同样本的损失，不要求单调；epoch 变化和负例长度都会影响数值。为避免只比较最后一步的不同样本，另在训练前后对同一完整偏好池关闭 dropout 逐条计算，结果见表 14。SFT 结束时的 DPO 初始 margin 已可为正，因为参考是基座而不是 SFT，无需人为制造“从负转正”。

表 14 全偏好池前后平均值

组别	loss 前→后	margin 前→后	正 margin 对数 前→后
12 对 β=.1	0.4978→0.2763	0.6072→2.3023	10→11 / 12
17 对 β=.05	0.5811→0.4119	0.2716→0.9125	13→14 / 17
17 对 β=.1	0.5113→0.3398	0.5432→1.6910	13→14 / 17
17 对 β=.5	0.5229→0.2534	2.7159→5.0068	13→14 / 17

9.5 β 敏感性与新增题检查

表 15 扩展 17 对的 β 扫描

β	语义 count/attr/exist	语义总计	原规则总计	新增题语义 /5
0.05	3/0/3	6/15	4/15	4/5
0.1	3/0/3	6/15	4/15	4/5
0.5	3/0/3	6/15	6/15	4/5

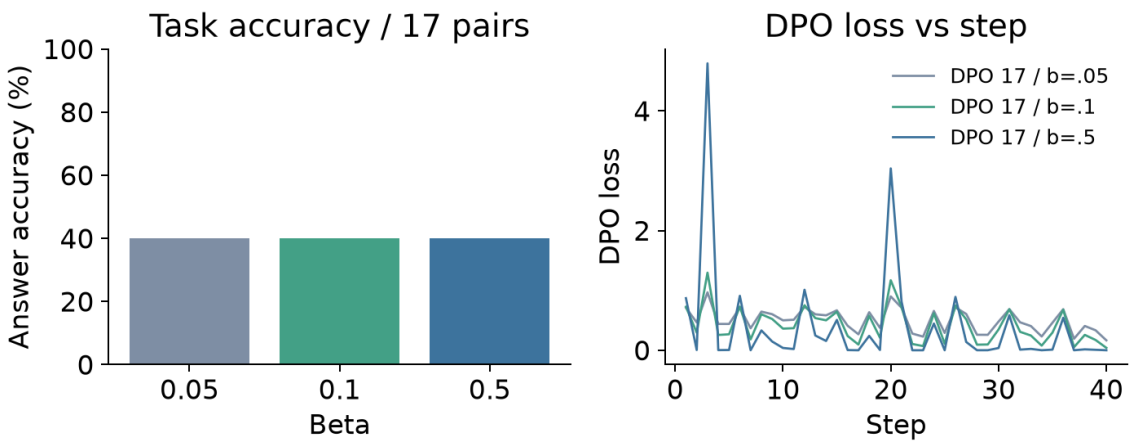


图 5 β 扫描语义正确率与逐步 DPO loss

表 16 新增偏好问题的主实验输出

题号	SFT	12 对 DPO	17 对 DPO β=.1	观察
A01	3 个。	4。	3。	扩充后恢复 3，避免 12 对的 4
A02	2 个。	2。	2。	三阶段语义计数都正确
A03	的。	行。	的。	仍未回答圆形，未压住对应失败
A04	没有。	没。	没。	没按否定可判对；完整性较 SFT 低
A05	2 个。	5 个。	2 个。	都未新增红方解释；不能声称 DPO 独自消除该幻觉

结论：新增数据补回部分训练题表现，β 影响输出形式及偏好目标的数值，却没有提高本组新增题或主集的语义正确率。不能仅按最后 loss 最低选出所谓最优 β；需要独立图像、平衡正负存在性题和跨种子复测。本报告保留这些局限，不以样板预期替代实际结果。

复核记录与参考资料

本地 11 项行为测试通过；独立检查 115 个原始文件、15 图真值、140 份生成、220 个优化步和全部适配器参数。原始训练源快照保留在 provenance/source_at_run.py，当前版本补充三阶段 eval 入口并修正评分边界，训练逻辑未改；140 份原规则复算无变化，语义审计 10 条差异可逐项定位。基座约 490MB 未提交仓库，通过固定 revision 及下载哈希复现；模型哈希记录来自 HPC 下载检查。完整代码、JSON、适配器、图表与复核记录归档至 lab05。

[1] 课程资料 作业五实验指南、报告样板、Lesson10 大语言模型微调。

[2] Hugging Face SmolVLM-256M-Instruct 模型卡与处理说明。
https://huggingface.co/HuggingFaceTB/SmolVLM-256M-Instruct

[3] Hu E J, et al. LoRA Low-Rank Adaptation of Large Language Models. https://arxiv.org/abs/2106.09685

[4] Dettmers T, et al. QLoRA Efficient Finetuning of Quantized LLMs. https://arxiv.org/abs/2305.14314

[5] Rafailov R, et al. Direct Preference Optimization Your Language Model is Secretly a Reward Model. https://arxiv.org/abs/2305.18290

[6] Hugging Face PEFT 量化与低秩训练文档。
https://huggingface.co/docs/peft/developer_guides/quantization

[7] 哈工大深圳 HPC 平台帮助文档。http://hpc.hitsz.edu.cn/docs/zh/home